Universidad Nacional de Itapúa

Facultad de Ingeniería
Ingeniería en Informática

Trabajo Final de Grado

Infraestructuras SSI de Altas Prestaciones aplicadas a Banco de Datos

Autores:
Hugo Armando Sendoa
David Ernesto Krüger

Director:
Prof. Ing. Amin Mansuri

Asesores:
Prof. Mgter. Lic. Horacio Kuna
Prof. Ing. Sergio Pohlmann

Encarnación – Paraguay
2011

Universidad Nacional de Itapúa

Facultad de Ingeniería

HOJA DE EVALUACIÓN DE TFG

INTEGRANTES MESA EXAMINADORA:

- ……

- ……

- ……

- ……

- ……

CALIFICACIÓN FINAL:

Hugo Sendoa: _____ ( )

David Krüger _____ ( )

ACTA Nº:

FECHA:

…… ……..

Secretaria General **Decano**

DEDICATORIA

AGRADECIMIENTOS

INDICE DE CONTENIDO

RESUMEN

INTRODUCCIÓN

EL PROBLEMA

Un banco de datos es conocido como una concentración de datos organizados de forma tal que la información se mantenga atómica, fiable y permita un acceso rápido a ella.

Los sistemas de altas prestaciones brindan optimización de recursos para ser aprovechados en procesos de manera a que sean procesados de forma eficiente, eficaz y confiable.

El Centro de Investigaciones de la Facultad de Ingeniería de la Universidad Nacional de Itapúa en sus diferentes líneas de investigación realiza estudios con el fin de ser ente generador de conocimiento en post de la investigación científica. Impulsado por docentes y alumnos llevan adelante proyectos en donde los bancos de datos son algunas de las herramientas más importantes del uso cotidiano.

Consideramos que la necesidad de contar con los elementos que faciliten y promuevan a la investigación científica, además de ser teóricos, deben de ser aplicados y para ello contar con la presencia de una infraestructura que lo permita es altamente necesario. Es por ello que la ejecución de aplicaciones de Banco de Datos en infraestructura de altas prestaciones es un factor ausente y necesario para la comunidad educativa.

En la actualidad el Centro de investigaciones de la Facultad de Ingeniería tiene líneas de altas prestaciones y minería de datos que no disponen de una estructura que brinde un rendimiento optimizando el tiempo de proceso de las operaciones realizadas sobre banco de datos. Si bien muchas de las investigaciones se basan en tendencias tecnológicas, hasta la fecha estas bases teóricas no pueden ser aplicadas sobre entornos distribuidos complementados

con prestaciones que garanticen la ejecución de los mismos.

JUSTIFICACION

La elaboración de alternativas de solución no solo comprende en obtener todas las formas de resolución de la problemática, se basa en obtener un abanico de posibilidades que cumplan con el objetivo y además de ser viables se encuentren al alcance de los facilitadores.

El avance de tecnologías en microprocesadores y la reducción del tamaño del micro conductor permitieron que las empresas logren ordenadores específicos que provean prestaciones cercanas al óptimo buscado a altamente superior a la media de los demás ordenadores. Estos súper ordenadores son conocidos como Mainframes o Servidores dedicados. Definitivamente la incrementación del poder computacional vino acompañado de un incremento en el costo de los materiales y la tecnología utilizada para la elaboración de los mismos, es por ello que el costo de adquirir un centro de cómputo de estas características es considerado como una inversión que debe ser altamente justificada.

En la actualidad el auge de los sistemas distribuidos con tecnologías en las cuales computadoras separadas físicamente, pero unidas por un medio en el cual forman una red, permitieron dividir un problema de tamaño mayor a muchos problemas independientes y de menor tamaño, resolviendo de forma paralela partes de un todo.

La adquisición de estas alternativas que permitirían combatir la problemática relacionada a este trabajo se ven enfrentadas a las limitaciones presupuestales a la cual todo ente estatal se encuentra apegado. De esta manera, la adquisición de un mainframe como ordenador de computo para aplicaciones de banco de datos en el Centro de Investigación en Computación de la Facultad de Ingeniería, se vería obligado a competir con otras insuficiencias que son afrontadas por el ente y sujeto a una presupuesto con un periodo de aceptación

y aprobación mayor al necesario para satisfacer las necesidades actuales.

La adquisición de una infraestructura por parte del Centro disminuiría las prestaciones con respecto a un mainframe, aumentaría considerablemente las prestaciones con respecto a un ordenador de capacidades medias y por sobre todo no estaría sujeto a un presupuesto elevado.

Otro ítem a ser considerado durante la elección de un entorno de procesamiento para el Centro de Investigaciones, se debe al nivel de criticidad de los datos que son tratados en las diferentes líneas de investigación con las cuales el CICFI se encuentra trabajando. Esta última razón inclina la balanza por la optar por una infraestructura que provea altas prestaciones al centro, debido a que los estudios que serán la razón de uso del entorno no poseen datos críticos.

Si bien las limitaciones físicas con las cuales cuentan el tipo de infraestructuras distribuida (como trafico de red y uso de espacio físico entre otros) no alcanzan las prestaciones de un servidor dedicado, permite lograr altas prestaciones para problemas complejos en los cuales un ordenador de características medias no tendría capacidad, se necesitan disminuir costos y mantener el nivel de criticidad de datos establecidos.

OBJETIVOS

OBJETIVO GENERAL:

Implementar en el Laboratorio del Centro de Investigación en Computación de la Facultad de Ingeniería una infraestructura de altas prestaciones del tipo *Single System Image* (SSI) para aplicaciones basadas en banco de datos.

OBJETIVOS ESPECÍFICOS

- Plantear el entorno tecnológico sobre el cual se implementará la infraestructura de Alta Prestación.

- Aplicar la infraestructura del tipo SSI

- Integrar la herramienta de monitoreo visual para la infraestructura SSI.

- Evaluar el desempeño de la infraestructura mediante pruebas de rendimiento en aplicaciones de banco de datos.

- Elaborar una metodología de implementación de infraestructura de altas prestaciones SSI para aplicaciones de banco de datos.

1 MARCO TEÓRICO

1.1 COMPUTACIÓN DE ALTO RENDIMIENTO

La computación de Alto Rendimiento (HPC por sus siglas en ingles High Performance Computing) es un concepto que abarca un amplio espectro de la aún más extensa área de las Ciencias de la Computación, específicamente enfocado a brindar un sistema solido, claro, flexible y estructurado para garantizar el funcionamiento óptimo en la distribución de los recursos.

HPC esta relacionada con la “supercomputación”, y surgió de los principios de este termino y trabajo, en ocasiones estos dos términos son utilizados de manera indistinta. Sin embargo, el termino supercomputación es usualmente aplicado a infraestructuras con propósitos específicos, un subconjunto especifico de HPC. Las supercomputadoras suelen ser equipos mas poderosos y con sistemas especializados, y por lo tanto muy caros. Un ejemplo podría ser la supercomputadora Cray [BEAS90] o el sistema Thinking Machine [HILLI93] de 1980. Sin embargo, estos sistemas de supercomputación especializados han sido casi completamente reemplazados por clústeres de computadoras básicas no especializadas.

Las computadoras de CPU estándar están basados en la arquitectura de Von Neumann [BACK77], y básicamente cuentan con la restricción de poder ejecutar únicamente una instrucción a la vez, una tras otra (ejemplo: procesamiento en serie). De esta manera, la única opción para poder realizar cálculos mas veloces en este tipo de arquitectura era incrementando la velocidad con la que los cálculos eran realizados. Aunque esta velocidad de calculo ha aumentado de forma constante y rápida desde la invención del circuito integrado, el cual sigue la Ley de Moore [INTE05], muchos cálculos deseables son todavía tan complejos y extensos que incluso en el equipo serial mas rápido, estos requerirían semanas o inclusive anos para finalizar el computo. Sin embargo, muchas aplicaciones pueden dividirse en segmentos y estos segmentos

resolverse simultáneamente en varios equipos. Cuanto mas se puede dividir la aplicación, mayor será la ejecución en paralelo. Todas las aplicaciones HPC involucran la paralización y ejecución del computo en múltiples entornos distribuidos.

1.1.1 COMPUTACIÓN PARALELA Y DISTRIBUIDA

La computación paralela permite que varios cálculos sean ejecutados simultáneamente. Cuando los problemas complejos pueden ser segmentados en otros menos complejos que puedan ser resueltos concurrentemente (al mismo tiempo o en paralelo), en consecuencia es reducido el tiempo necesario para resolver dicho problema. Un punto importante en la paralización de aplicaciones es la frecuencia en que los segmentos de código necesitan comunicarse entre si. Algunos cálculos pueden ser divididos en segmentos que únicamente necesitan una comunicación parcial del resultado entre ellos e inclusive pueden no ser necesaria la comunicación [BARN11] .

Cuando las subtareas necesitan comunicarse entre si para poder realizar el calculo en paralelo, un nuevo conjunto de cuestionamientos se introducen que complican la escritura de tales programas correctamente. Específicamente la necesidad de concurrencia y la sincronización introducen potenciales errores de programación, como podría ser la condición de interbloqueos, lo cual se produce cuando dos o más tareas se bloquean entre sí permanentemente teniendo cada una de estas tarea un bloqueo en un recurso que las demás tareas están tratando de acceder [COFF71]. Estos problemas adicionales son el mayor obstáculo para la implementación de computación paralela y obtener una buena prestación paralela de un programa. Otra consideración para la computación paralela es que la sobrecarga de la comunicación puede y hará que se pierda todo el rendimiento en la ejecución simultanea de tareas. El incremento de velocidad de un programa es gobernado por la Ley de Amdahl [AMDA67], la cual que básicamente permite en teoría calcular la cantidad de aceleración que se puede obtener basada en la cantidad de cálculo que se puede realizar en

paralelo. En la actualidad, en donde los procesadores de múltiples núcleos ya son productos básicos, esta teoría requiere una mayor investigación basándose en el rendimiento del chip completo en lugar de centrarse en la eficiencia de cada núcleo [HILL08].

1.1.2 ARQUITECTURA DE PROCESAMIENTO EN PARALELO

Una taxonomia útil para organizar los sistemas de procesamiento en paralelo, con el principal motivo de estudiarlas [FLYN72], se basa en las instrucciones de control de secuencias de datos dispuestas en la arquitectura. Está dividida en:

- **SISD** (del inglés Single Instruction and Single Data): Tomando como ejemplo la Arquitectura de Von Neumann, corresponde a una única instrucción operando con una única secuencia de datos.

- **SIMD** (del inglés Single Instruction and Multiple Data): Una misma instrucción aplicada a múltiples secuencias de datos.

- **MISD** (del inglés Multiple Instruction and Single Data): Múltiples Instrucciones simultaneas aplicados a una única secuencia de datos.

- **MIMD** (del inglés Multiple Instruction and Multiple Data): trata sobre las arquitecturas que permiten un múltiple acceso a secuencias de datos por instrucciones múltiples. Tratando de organizar esta última a finales de la década del 90 se procede a subdividirla en dos secciones [DUNC90][HWAN94]:

    - **SMP** (del inglés Symetric MultiProcesing): Arquitecturas que comparten una memoria física única y cuya velocidad disminuye según se incrementan los procesadores.

    - **DMM** (del inglés Distibuited Memory Multiprocessing): Son sistemas

en las cuales el procesador posee su propia memoria, evitan problemas de bloqueos y evita el acceso a la memoria física principal.

En el ámbito de HPC, en la mayoría de los casos se trata de sistemas MIMD, aunque los sistemas SIMD, en forma de clústeres de computadores basados en GPU [FAN04], se están convirtiendo en un subconjunto significativo y muy prometedor en la labor en la computación de alto rendimiento. Los sistemas MIMD pueden ser divididos en dos grupos principales, los que comparten una memoria principal (SMP), y aquellos que no comparten una memoria (DMM). Al momento de implementar una infraestructura de Clúster, usualmente se hace uso de ambos tipos de la arquitectura MIMD. Un procesador de memoria compartida, también llamado SMP (del ingles Symmetric multiprocessor), es aquel donde varios CPUs conviven en la misma maquina, un ejemplo de esto son los procesadores múltiples núcleos.

1.1.3 HPC BASADO EN EL MODELO DE CLÚSTER

Existen varias formas de presentar un modelo correspondiente al cómputo en altas prestaciones, como por ejemplo una estructura basada en el Modelo de Clúster. En forma general se define la palabra clúster como un numero de elementos del mismo tipo agrupados entre si. Su definición proviene del idioma ingles [BUYY99] y es utilizado para definir un conjunto de elementos, de igual manera Tomas Sterling lo señalaba en su libro [STER02] en el cual realiza analogías con los sistemas biológicos, organizaciones humanas y estructuras de computadores.

Un clúster brinda flexibilidad de configuración. El número de nodos, la memoria disponible por nodo, el número de procesadores por nodo y la topología de red utilizada para la interconexión de las partes son los parámetros mas considerados a la hora de especificar el poder computacional del clúster. Otra característica muy bien vista por la comunidad tecnológica es la capacidad de adaptación a nuevas tecnologías de hardware y por tanto el incremento de la

capacidad de cómputo no se vería ligado de forma unilateral a la compra de un nuevo equipo y de forma condescendiente el desecho del anterior como sucede con los mainframes.

La clave del comportamiento del clúster se basa principalmente en el manejo de los planificadores de plazo [TANE96] y en la capacidad de interconexión entre los componentes de la red conocidos también como nodos del clúster.

1.3.1.1 Características de un clúster.

Es un hecho que la mayoría de los más grandes problemas estratégicos en las cuales se aplica el cálculo numero en relación con las ciencias de la computación, solo puede ser resueltas mediante un maquina cuya ingeniería permita realizar un computo complejo.

De manera desafortunada para usuarios o empresas el costo de estos ordenadores no compensa la necesidad en un factor de costo o tiempo de uso. Es por ello que las alternativas viables para tener acceso a esta disponibilidad fueron siempre aceptadas y estudiadas.

El punto en el cual se unen las necesidades de disponibilidad, rendimiento y bajo costo de forma sinérgica dieron inicio a una tendencia que se expandió de acuerdo a la demanda de las necesidades. Es punto es conocido como Computación en Conjunto (del ingles Clúster Computing) cuya características principales se basan en la unión de una capa física de nodos, una abstracción del manejo del paso de mensajes y la aplicación de tecnologías Distribuidas.

1.2 MIDDLEWARE SSI

El middleware puede ser considerado como una capa software que reside entre las aplicaciones y los niveles subyacentes como son el sistema operativo, las pilas de protocolo y el hardware [SCHA02]. Históricamente el concepto de middleware no proviene de la investigación académica, sino de la industria.

Una imagen de sistema único SSI (por sus siglas en ingles) es una propiedad de un sistema que oculta la distribución y heterogeneidad de sus recursos. y los vuelve disponibles a los usuarios y aplicaciones como un recurso computacional unificado. SSI provee a los usuarios una vista globalizada de los recursos disponibles en el sistema, desconsiderando al nodo al cual este asociado físicamente dentro del entorno distribuido. Además, SSI puede asegurar la continua operatividad del sistema luego de una falla (alta disponibilidad) así también garantiza que el sistema se cargue uniformemente, provea multiprocesamiento y gestión de los recursos.

Los objetivos de un diseño SSI para un sistema basado en Clúster se enfocan principalmente en la transparencia complete de la gestión de recursos, el rendimiento escalable, y la disponibilidad del sistema para el soporte de las aplicaciones para usuarios [BUYY99]. SSI puede ser definido como una ilusión creada por hardware o software, el cual presenta una colección de recursos como un único recurso mucho más poderoso [PFIS98].

1.2.1 SERVICIOS Y BENEFICIOS DE MIDDLEWARE SSI

Los principales servicios de una imagen de sistema único SSI incluyen los siguientes [BUYY99]:

- Proporciona una visión simple y directa de todos los recursos y actividades del sistema desde cualquier nodo del clúster.

- Libera al usuario final de tener que saber en que parte del clúster se ejecutará la aplicación.

- Permite el uso de los recursos de manera transparente con independencia de su ubicación física.

- Permite el trabajo del usuario por medio de una interfaz amigable y permite al administrador gestionar al clúster como una sola identidad.

- Ofrece la misma sintaxis de comandos como de otros sistemas y por lo tanto reduce el riesgo de errores de operaciones y con este resultado los usuarios finales observan un mayor rendimiento, fiabilidad y mayor disponibilidad del sistema.

- Permite centralizar/descentralizar la gestión del sistema y el control para evitar la necesidad de administradores expertos para la gestión del sistema.

- Simplifica de gran manera la gestión del sistema y reduce así el costo de propiedad.

- Proporciona la comunicación de mensajes sin dependencia de localización

- Beneficia a los desarrolladores de sistemas en la reducción del tiempo, esfuerzo y conocimientos necesarios para la realización de tareas que permiten al personal actual manejar grandes o más complejos sistemas.

- Promueve el desarrollo de herramientas estándares y servicios.

Un buen SSI se obtiene usualmente mediante la cooperación entre todos estos niveles, un nivel más bajo pueden simplificar la implementación de un ser superior.

1.2.2 SSI AL NIVEL DEL SISTEMA OPERATIVO

Los sistemas operativos de los Clúster soportan una eficiente ejecución de aplicaciones paralelas en entorno distribuido con aplicaciones secuenciales. El objetivo es reunir los recursos en un clúster para proporcionar un mejor rendimiento tanto para las aplicaciones secuenciales y paralelas.

Para lograr este objetivo, el sistema operativo debe de ser compatible con la programación planificada en masa de algoritmos paralelos [SCHE98], identificación de los recursos ociosos en el sistema, tales como procesadores, memoria y redes; además ofrecen acceso globalizado a ellos. Debe soportar de manera optima el proceso de migración para proporcionar equilibrio de carga dinámica, así como la comunicación entre procesos rápidos, tanto par alas aplicaciones del sistema y de nivel de usuario. El sistema operativo debe asegurarse de que estas características estén disponibles para el usuario sin la necesidad de llamadas adicionales al sistema.

A continuación se listan os sistemas operativos más representativos que soportan SSI al nivel de kernel:

1.2.2.1 SCO Unix Ware Non Stop Cluster

Es el software de alta disponibilidad de SCO. Amplia significativamente el soporte por hardware, por lo que es más fácil y menos costoso de implementar el software de clustering mas avanzado para sistemas Intel. Es una extensión para el sistema operativo UnixWare en el cual todas las aplicaciones se ejecutan de manera eficaz y fiable dentro de un entorno SSI el cual elimina toda la gestión de carga. Cuenta con IP estándar como la interconexión, eliminando la necesidad de algún hardware propietario. La arquitectura clúster de Unix Ware Non Stop ofrece soporte integrado para aplicaciones de conmutación por error mediante un enfoque de *n + 1*. Con este enfoque, la copia de seguridad de la aplicación puede ser reiniciada en cualquiera de los varios nodos dentro del

clúster. Esto permite que un nodo actúe como un nodo de copia de seguridad para los demás nodos dentro del clúster [WALK99].

1.2.2.2 Sun Solares-MC

Es una extensión prototipo de un kernel Solaris de nodo único. Proporciona imagen de sistema único y alta disponibilidad al nivel del kernel. Solaris MC esta implementado mediante técnicas de orientación a objetos. Utiliza de manera amplia el lenguaje de programación orientado a objetos de C++, el modelo estándar de objeto y el lenguaje de definición de interfaz de COBRA. Solaris MC utiliza un sistema de archivos global llamado Proxy del Sistema de Archivos PXFS (las siglas en ingles de Proxy FileSystem). Las características principales incluyen la imagen de sistema único, la semántica coherente y de alto rendimiento. El PXFS hace que los accesos a ficheros se vuelva transparente para los procesos. PXFS logra una imagen de sistema único por medio de la interceptación de las operaciones de accesos a archivos a nivel de la interfaz vnode/VFS (WritingFileSystem, instancias para la operatividad de los FileSystems). Solaris MC asegura que las aplicaciones de red no necesiten ser modificados y observen la misma conectividad de red, independiente de en que nodo se este ejecutando la aplicación [MATE95].

1.2.2.3 GLUnix

Otra alternativa disponible para que el sistema operativo soporte SSI es la implementación de una capa superior en el sistema operativo existente, la cual realiza las asignaciones globales de los recursos. Este es el enfoque seguido por GLUnix de Berkeley. Esta estrategia vuelve portable al sistema operativo y reduce el tiempo de desarrollo. GLUnix es una capa del sistema operativo diseñado para proveer soporte en la ejecución remota transparente, trabajos paralelos y secuenciales, balanceo de carga y compatibilidad con versiones anteriores de binarios de aplicaciones existentes. GLUnix esta completamente implementado en el nivel de usuario y no necesita modificación en el kernel, por

lo que se vuelve mas fácil de implementar. Las principales características proporcionadas por GLUnix incluyen técnicas de planificación en paralelo de algoritmos paralelos; detección de recursos ociosos, proceso de migración, y balanceo de carga; comunicación rápida a nivel de usuario, y soporte de disponibilidad [GHOR98].

1.2.2.4 MOSIX

Mosix es una extensión del kernel de Linux que permite ejecutar aplicaciones no paralelizadas en un Clúster. Una de las posibilidades de MOSIX es la migración de procesos, que permite trasladar los procesos de nodo en nodo. Mosix opera de manera inadvertida y sus operaciones son transparentes para las aplicaciones. Esto significa que se pueden ejecutar aplicaciones secuenciales y paralelas al igual que lo haría un SMP (Sistema de Multiprocesamiento simétrico, Symmentric multiprocessing). No es necesario prestar atención en donde el proceso se esta ejecutando o lo que otros usuarios podrían estar realizando. Poco después de que un nuevo proceso haya sido creado, Mosix intenta asignarlo al mejor nodo disponible en ese momento. Luego de esto, Mosix continua monitoreando el nuevo proceso, asi como también los otros procesos existentes, evaluara los nodos para maximizar el rendimiento global. Todo esto es realizado sin necesidad de alterar la interfaz de Linux. Esto significa que todos los procesos pueden ser monitoreados y controlados como si estuviesen ejecutándose en un nodo en particular. La última versión de Mosix, llamada MOSIX2 es compatible con Linux 2.6. MOSIX2 es implementada como una capa virtualizada del sistema operativo, lo que provee al usuario y a las aplicaciones una imagen de sistema único SSI [BARA98].

1.2.2.5 OpenMosix

El sistema OpenMosix esta basado en Mosix, la principal diferencia, se encuentra en su licencia GPL. OpenMosix es un conjunto de parches al kernel y unas utilidades y bibliotecas de área de usuario que permiten tener un sistema

SSI completo para Linux. Al estar basado en el código de MOSIX, comparte algunas de sus características y limitaciones. OpenMosix hace uso del parche de Rik van Riel de mapeado inverso de memoria, que permite que el proceso que consume más recursos de OpenMosix pase de tener una complejidad computacional de *O(n)* a una complejidad *k*. En la práctica, elimina una de las partes del código de OpenMosix que pueden consumir una cantidad apreciable de procesador. OpenMosix fue lanzado como un parche para el kernel de Linux, pero también estuvo disponible en Live CDs especializados. El desarrollo de OpenMosix ha sido detenido por sus desarrolladores, pero el proyecto LinuxPMI continúa su desarrollo por medio del código OpenMosix [LOTTI05].

1.2.2.6 Kerrighed

Kerrighed es el resultado de un proyecto de investigación iniciado en 1999. Su objetivo es presentar un único SMP (Sistema de Multiprocesamiento simétrico, Symmentricmultiprocessing) por encima del clúster. Kerrighed se compone de un conjunto de servicios distribuidos del kernel a cargo de la gestión general de los recursos del cluster [LOTTI05][MORI04].

1.2.2.7 OpenSSI

OpenSSI surge a inicios del año 2001, esta basado en los proyectos Non-Stop Cluster de UnixWare [WALK99]. Bruce Walker, director del proyecto y principal desarrollador de OpenSSI, demarco claramente que el objetivo era crear una plataforma para poder integrar tecnologías de clúster, con código abierto. La ultima versión de OpenSSI dispone de varios archivos del sistema y manejo de sistemas de disco en código abierto, como por ejemplo GFS, OpenGFS, Lustre, OCFS, DRBD, también integra un mecanismo de bloqueo distribuido (OpenDLM) y una política para obtener balanceo de carga, siendo esta una característica importante heredada de Mosix. OpenSSI permite el balanceo de carga de un clúster dinámicamente mediante el uso de migración de procesos, otra característica también heredada de Mosix. El modulo de migración de procesos

de OpenSSI utiliza un mecanismo de acceso al recurso remoto manteniendo los recursos de acceso del sistema bloqueados para que estos no puedan ser migrados. Este mecanismo es usado principalmente en IPC (interfaz de la tarjeta de red), CFS (sistema de archivos del clúster) y también para algunas llamadas al sistema [BARA98].

1.3 BENCHMARKS

Toda infraestructura o sistema debe ser evaluado para conocer las ventajas y/o inconvenientes que puedan presentarse. Para ello se pretende cuantificar los resultados obtenidos de modo a comparar el rendimiento. Existen varias formas de elaborar una evaluación de rendimiento y la tendencia es evaluar los elementos bajo situaciones ideales. En este capítulo se presentan los conceptos básicos y los resultados obtenidos, así como la metodología aplicada para la obtención de estos.

Se denomina benchmark al o los procesos que son ejecutados en una máquina para proveer una carga de trabajo significativa con el fin de medir el rendimiento. Existen diferentes formas de realizar un benchmark, de los cuales podemos destacar a las generadas por una aplicación, función o procedimiento específico [DONG83] , la ejecución de un test iterativo de una subrutina [BAIL86] o programas sintéticos que analizan el rendimiento individual de cada componente en un ambiente real, brindando una noción del comportamiento [BOUT06].

Los benchmark miden el rendimiento y para ello deben satisfacer características consideradas como necesarias en el performance [BAIL86] como:

Capacidad de cálculo del procesador:

Independientemente, cada ordenador posee un procesador, cuyas características propias son incrementadas al formar parte de un conglomerado debido a la distribución de carga de trabajo, no obstante ante excesivas cargas el microprocesador debe responder de forma óptima. Este debe ser contrastado con las especificaciones técnicas del hardware. En la actualidad existen muchas herramientas que nos ayudan a medir estas capacidades mediante operaciones matemáticas [DONG95][NUMR07]

Velocidad de I/O (del ingles Input/Output o entrada y salida):

En el común de las situaciones los sistemas que brindan rendimiento, trabajan con operaciones que requiere un espacio de memoria adicional debido a la complejidad de operaciones que dan como resultante la situación final, ejemplo de ello son las operaciones conocidas como Procesos de Transaccion en Linea o OLTP (por sus siglas del Ingles OnLine Transaction Processing) ampliamente utilizadas en el comercio electrónico y transacciones bancarias [CHEN10].

La comparación de estas características medibles con respecto a otros valores brinda la percepción de mejor o peor rendimiento respecto al punto comparado.

La aplicación de benchmark se encuentra ligada a obtener métricas de software, infraestructura o un conjunto de ellas caracterizadas por las unidades que son consideradas para obtener un valor cuantitativo. Es por ello que dependiendo del uso dado, pueden variar las métricas o puntos de referencias establecidos por un estándar.

Cuando las pruebas de test son realizadas en su totalidad, provee información que debe ser estudiada. El análisis de esta permite conocer las características y el comportamiento de los componentes ante situaciones similares. Este proceso es conocido como caracterización de pruebas. [GARC08].

La comparación de estas características medibles con respecto a otros valores brinda la percepción de mejor o peor rendimiento respecto al punto comparado.

La aplicación de benchmark se encuentra ligada a obtener métricas de software, infraestructura o un conjunto de ellas caracterizadas por las unidades que son consideradas para obtener un valor cuantitativo. Es por ello que dependiendo del uso dado, pueden variar las métricas o puntos de referencias establecidos por un estándar.

Cuando las pruebas de test son realizadas en su totalidad, provee información que debe ser estudiada. El análisis de esta permite conocer las características y el comportamiento de los componentes ante situaciones similares. Este proceso es conocido como caracterización de pruebas. [GARC08].

1.3.1 TIPOS DE BENCHMARKS

De manera a clasificar los benchmark se encuentran:

1.3.1.1 Micro benchmark:

Sentencia o conjunto de instrucción dedicada a la evaluación de un solo componente del sistema [LILJ05]. Generalmente, al ser tan pequeño, cabe en la memoria y presenta evaluaciones erróneas debido al cacheo.[BERS92][LIU04]

1.3.1.2 Toy Benchmark:

Son programas completos que realizan operaciones de manera dispersa, si este corresponde a una sección del núcleo del programa en un bucle se lo llama Program Kernels. Sus limitaciones de ejecución no son consideradas como test completos y deben ser complementados [LILJ05].

1.3.1.3 Benchmark Sintético:

Es un conjunto de aplicaciones en un solo programa, utilizado para medir partes de un sistema. Trabajan de manera directa con la sección a ser tratada y, contrariamente a los benchmark de aplicación, no reflejan un trabajo real debido a que trabaja de forma aislada, demostrando la situación ideal del objeto o sección del sistema en observación. [CHEN93][CURN76]

1.3.1.4 Benchmark de Aplicación:

provee un conjunto de programas o instrucciones estándares que se encargan de similar una carga de trabajo completa, de manera tal como el sistema se comportaría ante una situación cercana a la realidad. Este tipo de benchmark

provee una medida de variables durante su ejecución y por ende es importante aislar estos elementos que son considerados como objeto de estudio [LILJ05].

1.3.2 APLICACIÓN DE BENCHMARKING A BASE DE DATOS

La aplicación de Benchmark a Base de datos es un área en el cual se desarrollan varias investigaciones debido a su importancia en incrementar las prestaciones de las operaciones diarias de negocios (conocido como Business Operation), así como también en las proyecciones de mercado (o Business Intelligence). La gestión de las múltiples transacciones pequeñas bajo el esquema de OLTP, en contraste de las complejas consultas históricas utilizadas por el esquema OLAP (por sus siglas del ingles On Line Analytical Processing o Procesamiento analítico en línea) permiten tener un amplio panorama en todas las operaciones comúnmente utilizadas en la administración de datos

Si la aplicación de un benchmark es dada a una base de datos se deben tener en cuenta los criterios de:

Capacidad de cálculo:

Específicamente las operaciones de punto flotante son las más resaltantes debido a su complejidad.

Interbloqueo de transacciones:

El tiempo de bloqueo entre operaciones que transaccionan en un mismo instante influye considerablemente en cargas de trabajos de magnitud.

Velocidad de Acceso a Disco (I/O):

Debido a que se manejan datos históricos y por la magnitud de estos no pueden ser alojados en memoria dinámica y por ello deben ser alojados en medios de almacenamientos. Para datos del esquema OLTP suelen manejarse de manera interna, en cambio para el esquema OLAP los datos pueden ser alojados

externamente a la infraestructura principal [SZEP11].

Se considera como objeto de validación la aplicación de un benchmark al banco de datos en diferentes situaciones de manera a verificar el comportamiento de la Base de Datos.

El resultado de estas pruebas define el comportamiento de la base de datos en diferentes escenarios contrastándolos con la infraestructura SSI.

Necesariamente la verificación de una base de datos en busca de rendimiento se debe realizar emulando el trabajo regular en situaciones que se presentan de manera frecuente, es por ello que todo benchmark aplicado debe realizar sentencias SQL sobre la estructura en cuestión.

Varias organizaciones realizaron una definición para ser considerada como estándar y proveen formas de medir y reportar los resultados arrojados. Entre ellas podemos encontrar los estándares como SPEC [SPEC11], TPC [TPCC11], Perfect Club [BERR89], The Open Source Database Benchmark [OSDB10], The NAS Parallel Benchmark [NAPB10], HPL [HPLB08] y otros.

2. MARCO METODOLÓGICO

2.1 DISEÑO METODOLÓGICO

Basados en la estructura y procedimientos planteados según la finalidad de este trabajo final de grado fue una investigación aplicada tecnológica, a fin de generar nuevos conocimientos y brindar un producto a la institución, llevada a cabo mediante estrategias metodológicas fueron de tipo cuantitativas, orientando al resultado, buscando obtener datos sólidos y repetibles, generalizables, y particulares. Por su objetivo este trabajo final de grado fue descriptivo a fin de ir detallando los procesos en los cuales se fue trabajando.

Los procedimientos adoptados a fin de ir estructurando sistemáticamente nuestra estrategia de trabajo fueron de la siguiente manera:

Mediante actividades de refinamiento de la investigación documental orientada a la identificación de trabajos previos vinculados a la computación de altas prestaciones y su impacto actual en el entorno académico, fueron:

- Estudio e implementación del entorno tecnológico apropiado para la infraestructura de Alta Prestación.
- Estudio e identificación de técnicas de validación de los procedimientos desarrollados una vez integradas las herramientas a fin de determinar la capacidad máxima a soportar por parte de la infraestructura sin perder rendimiento.
- Implementación y adaptación de una aplicación grafica, basada en View Web, que permita el monitoreo de recursos de la infraestructura.
- Elaboración, implementación y resumen de pruebas de rendimiento a la Infraestructura.
- Redacción del informe del trabajo final de grado realizada mediante los procesos de investigación expuestos anteriormente.

2.2 DEFINICIÓN DEL ENTORNO TECNOLÓGICO APROPIADO PARA LA INFRAESTRUCTURA DE ALTA PRESTACIONES.

2.2.1 USO DE CLÚSTER SSI COMO ALTERNATIVA VIABLE A UN ENTORNO DE ALTA PRESTACIONES PARA BANCO DE DATOS.

De manera a afrontar esta problemática se busco un punto de inflexión en donde se encuentra la brecha de la relación costo - rendimiento brindando servicios de manera transparente y cuyo resultado desemboca en las tecnologías distribuidas.

Por los antecedentes, la propuesta de proveer al Centro de Investigación en Computación de la Facultad de Ingeniería un entorno distribuido de bajo costo para procesos de Banco de Datos, se relaciona directamente con la unión de ordenadores físicos disponibles en el ente coordinados mediante una interconexión física y abstrayendo el paso de mensajes .

La utilización de entornos distribuidos de las características anteriormente mencionada requirió en la mayoría de los casos alterar la fuente de las operaciones, adaptándolos para el cálculo distribuido, es por ello que la propuesta de utilizar una capa que abstrae esa adaptación es incluida en esta propuesta.

2.2.2 OPTANDO POR OPENSSI COMO UN CLÚSTER DE ALTO DESEMPEÑO Y BALANCEO DE CARGA

En los clústeres SSI de alto rendimiento los programas no tienen por que notar que se están ejecutando en uno de ellos. El único requisito es que los programas desplieguen múltiples procesos, los cuales se asignan de forma transparente entre los ordenadores del clúster. Aunque los clústeres SSI no son tan escalables como otros tipos, ofrecen sin embargo la significativa ventaja de que los programas que se ejecutan en el sistema no tienen que conocer la existencia del clúster en el que se estén ejecutando. Otras plataformas de alto rendimiento basadas en clústeres requieren que el código fuente de los

programas contengan código propio del clúster, o al menos que el programa se enlace con alguna librería de este. OpenSSI es una solución de clúster SSI extensa de código abierto para Linux basada en la plataforma clúster NonStop de HP. NonStop deriva de Locus, que se desarrollo en los ochenta.

OpenSSI puede repartir los procesos de forma transparente entre múltiples máquinas, característica conocida como nivelado de carga [WALK05]. Otras plataformas de clúster SSI para Linux capaces de realizar el nivelado de carga son OpenMosix y Kerrighed. OpenMosix es el clúster SSI mas popular de Linux. En julio del 2007 se anuncio que el proyecto OpenMosix terminaría en marzo de 2008. Kerrighed es relativamente nuevo, encontrándose actualmente en una fase de desarrollo rápido.

OpenSSI monitoriza constantemente la carga en los ordenadores del clúster y migra automáticamente los procesos entre los nodos. Este sistema es capaz de migrar una aplicación multihilo, pero no es capaz de migrar hilos individualmente. Un proceso migrado puede continuar con las mismas operaciones que estaba realizando en la máquina original, puede leer y escribir en los mismos ficheros o dispositivos e incluso puede continuar una comunicación interproceso (IPC) sobre un socket.

La mayoría de las aplicaciones se ejecutaron en OpenSSI sin ninguna modificación, con algunas excepciones, tal y como se indica en la página de ayuda del comando *migrate*. OpenSSI también proporciona una librería (API) que los programadores pueden utilizar para controlar el clúster.

Se sabe que OpenMosix es el sistema de clúster más conocido y usado, sin embargo, aunque es difícil luchar contra un sistema plenamente acogido, desarrollado y mejorado por muchísima gente de diferente índole, OpenSSI, con cada actualización de Kernel nueva va ganando más adeptos y haciéndose un hueco entre el mundo de la supercomputación.

2.2.2.1 Características de OpenSSI

A continuación se muestran las características más importantes de OpenSSI:

- Manejo y administración del dominio de forma sencilla.
- Sistema de archivos de la raíz generado a través del clúster de forma sencilla.
- Copia sencilla de archivos binarios, librerías y administradores (como una contraseña).
- Se puede manejar los procesos por todo el clúster de manera sencilla según su PID.
- El nombre del clúster está disponible para todos los objetos del IPC.
- Contiene un dispositivo de acceso al clúster
- Nombrado de entidades consistente a lo largo de los nodos.
- Los archivos de acceso a todos los nodos son completos y públicos.
- La tecnología del sistema de archivos del clúster la tiene integrada y le provee flexibilidad y elección.
- Las interfaces del núcleo permitirán otra tecnología que esté desarrollada en código abierto.
- Está disponible un sistema de archivos del clúster con un failover público.
- El nombre y la dirección del clúster será altamente disponible, pudiéndose

acceder a el siempre.

- La migración de procesos se puede realizar de forma completa incluyendo las llamadas al sistema.

- El balanceo de carga de un proceso se realiza en tiempo de ejecución.

- Incluye un conjunto de características de disponibilidad.

- Monitorización y reinicio del proceso.

- Servicio automático de failover.

- Sistema de archivos automáticos del failover.

- Dirección IP del clúster, manejo de la conexión y la habilidad de perder el nodo inicio sin matar a los procesos que están corriendo.

- Garantía y un API para los miembros que usan una infraestructura de un Clúster bajo Linux.

- Un API para migrar los procesos según los métodos: rexec() y fork()

- Nodos que no necesitan discos gracias al arranque por red

2.2.2.2 Limitaciones de OpenSSI

En OpenSSI se debe de tener en cuenta ciertas limitaciones para que funcione correctamente, a continuación se muestra un listado de las limitaciones que se deben cumplir:

- Miembros del clúster: El número máximo de nodos en un clúster es de 125.

- El sistema de archivos de un clúster (CFS): Tamaño máximo de ficheros, número máximo de ficheros, direcciones y sistemas de archivo físicos inherentes.

- UID/GID: 16-bit en OpenSSI-1.2. 32-bit en OpenSSI-1.9.

- Tipos de dispositivos principales: 255 en OpenSSI-1.2. 4095 en OpenSSI-1.9.

- Tipos de dispositivos secundarios: Número máximo de puntos de montaje por tipo de sistema de archivos. 8-bit in OpenSSI-1.2. 20-bit in OpenSSI-1.9.

- IPC: Máximo número de semáforos compartidos.

- Sockets: Máximo número de sockets.

- Procesos: Máximo número de procesos. 32,000 en OpenSSI-1.2 y 1 billón(americano) en OpenSSI-1.9.

- PTY: Máximo número de pty's.

- HA-LVS: Máximo número de conexiones, de directorios, de CVIP. Igual que el original LVS, millones de conexiones.

- DRBB-SSI: Máximo tamaño del volumen por dispositivo de drbd, máximo de dispositivos drbd. Igual que el original DRBD.

3. RESULTADOS Y ANALISIS

3.1 IMPLEMENTACIÓN DEL CLÚSTER OPENSSI

Como se habló en la sección 2.2.2 *Optando por OpenSSI como un clúster de alto desempeño y balanceo de carga*, la distribución de procesos en los nodos del clúster es la principal característica de funcionalidad de OpenSSI. De una forma ideal, los procesos buscaran ejecutarse en un ambiente igual o muy similar del nodo donde provienen, con mejores recursos de memoria y procesador. Hablando en términos del programa, éste estaría ejecutándose en nodos externos, por lo que es indispensable que el procesador externo tenga el conjunto de instrucciones necesarias para poder procesar el código compilado en el nodo anfitrión, de otra forma el programa no podría ejecutarse.

Con base en estas observaciones, se concluye que la construcción de un clúster OpenSSI como en otros tipos de clústeres es ideal que se haga con hardware homogéneo, aunque muchas de las veces debido a los recursos con los que se pueden disponer en nuestro centros de investigación no es posible cumplir con este requerimiento, no indispensable pero si recomendado, pues además de proveer un ambiente de ejecución adecuado para los procesos, facilita la administración del software instalado en los nodos del clúster.

3.1.1 REQUERIMIENTOS PARA LA IMPLEMENTACIÓN DE OPENSSI

3.1.1.1 Requerimientos de Hardware

La elección del hardware a utilizar en un clúster puede definirse primeramente en base a conocer la magnitud del problema o problemas que se quieren resolver, el hardware que puede adquirirse en el mercado, los recursos económicos y humanos con los que se cuentan, tanto para administrar el clúster cómo para programar y ejecutar las aplicaciones. Cuando se planea la adquisición, se propone la compra del “mejor” equipo de computo.

La descripción de estos nodos es una propuesta ideal para ensamblar el clúster,

en ésta también se describe el tipo de red o canal de comunicación que se recomienda, aunque por supuesto es hardware que cumple con los requerimientos básicos. Cabe aclarar que se propone la construcción de un clúster especifico, pues su propósito, problema o proyecto en particular, que se ha propuesto es para la ejecución de banco de datos.

En el capítulo 4. *Conclusiones y Recomendaciones*, en las pruebas de rendimiento se mostrará la utilidad de OpenSSI en relación a motores de banco de datos, por tanto se propondrá el diseño de un clúster que pueda en el mayor de los casos responder a las necesidades generales.

Se identifican como nodos aquellas unidades individuales de procesamiento en el clúster. Para la implementación de un clúster OpenSSI, el hardware soportado es para las arquitecturas IA32 y compatibles, es decir, en términos del hardware disponible en el mercado se refiere a los procesadores Intel y AMD con tecnología para procesamiento de palabras de 32 bits. OpenSSI ha sido desarrollado y probado para funcionar en estos dos tipos de procesadores y no es ideal ensamblar clústeres con ambos tipos de procesadores.

Los factores en la elección de uno u otro tipo de procesador son principalmente su costo y también por supuesto el software que se podrá aprovechar al máximo. Como ejemplo, se puede mencionar que por cuestiones de mercado, los procesadores AMD han sido más económicos sin querer decir con esto que tengan un menor rendimiento o tecnologías más obsoleta o atrasada, pero en cuanto al desarrollo de aplicaciones de software comerciales y no comerciales, como por ejemplos los compiladores, estas han sido desarrolladas y optimizadas para los procesadores Intel. Esto no quiere decir que sea imposible de implementar un clúster de bajo costo con hardware de bajo costo, simplemente se requiere en la mayoría de los casos un estudio de las herramientas disponibles para optimizar las aplicaciones de los usuarios.

Para este trabajo, el hardware requerido se encuentra disponible en el Centro de Investigación de Computo de la Facultad de Ingeniería, C.I.C.F.I.; allí se implementó la infraestructura de un clúster conformado por 3 nodos. A continuación se listara el hardware disponible de manera ilustrativa, no se abarcara en detalles los dispositivos periféricos (teclado, mouse, etc.), estas quedan a criterio de las necesidades reales que se pueda dar a estos dispositivos en el clúster

Procesador	AMD Athlon(tm) Processor LE-1640 Processor Speed: 2.6 GHz. L2: 1 MB.
Memoria (RAM):	3 GB DDR-2 800 MHz.
Disco Duro (Hard Disk):	250 GB, SCSI de 15,000 rpm.
Placa Madre (Motherboard):	ASUSTeK Computer INC. M2N-MX SE Plus System Bus Speed: 800 MHz. System Memory Speed: 667 MHz.
Tarjeta de Red	Intel (R) Pro/100 Network Conecction Fast Ethernet

3.1.1.2 Requerimientos de Software

Sistema Operativos:

Debian GNU/Linux es un sistema operativo libre que soporta un total de doce arquitecturas de procesador e incluye los entornos de escritorio KDE, GNOME, Xfce y LXDE. La versión 5.0.8 Lenny con kernel 2.6 es compatible con las versiones openssi 1.9.6 y la versión alpha de openssi 2.0.

Sistema de Archivos:

Ext3: Sistema de archivo utilizado para las particiones Linux, incluye la característica de *journaling* que previene el riesgo de corrupciones del sistema de archivos y es de los más utilizados por presentar mejor desempeño en el manejo de archivos.

Cluster File System (CFS): Sistema de archivos distribuidos pertenecientes a un grupo de servidores que trabajan en conjunto para proporcionar un servicio de alto rendimiento para sus usuarios en vez de un único servidor con un conjunto de clientes. Para los usuarios del clúster el sistema de archivos es transparente, simplemente un sistema de archivos. El programa de manejo del sistema de archivos se encarga de distribuir las solicitudes a través de los elementos del almacenamiento del clúster. Los sistemas de archivos en clúster (CFS) permiten que múltiples servidores puedan acceder al mismo sistema de archivos. CFS resuelve las desventajas y complejidades de los discos duros proveyendo una solución más simple para la administración del almacenamiento

Herramienta de Monitoreo:

Openssi webView: Aplicación grafica de monitoreo de OpenSSI, con ella puede realizarse parte de las tareas comunes de monitoreo que se harían con los comandos. El propósito de esta herramienta es la de proveer una visión general del estado del clúster, graficar las funciones claves del sistema. Permite al administrador del clúster controlar el estado de los recursos de cada nodo y de la infraestructura en general.

3.1.2 ORGANIZACIÓN DE LOS NODOS

En esta sección se da una descripción de la topología de la red y de los componentes de la conexión entre nodos del clúster, como son el switch y el cable de red utilizados. Cabe mencionar que esta configuración es parte de la red actual del Centro de Investigación en Computación de la Facultad de

Ingeniería (CICFI).

La topología de red utilizada es la estrella, se caracteriza por tener todos sus nodos conectados a un controlador central, en este caso, un switch de 8 nodos de los cuales 4 nodos pertenecen al clúster. Todas las comunicaciones pasan a través del switch, siendo éste el encargado de controlarlas. Por este motivo, el fallo de un nodo en particular es fácil de detectar y no daña el resto de la red, pero un fallo en el controlador central desactiva la red completa.

El cable con el que están conectados los nodos del clúster al switch que los une, es estructurado de la marca Kron, para velocidades de transmisión de datos Ethernet 10/100/1000.

Los equipos conectados a este switch se conectan a una velocidad auto negociable de 10Base-T/100Base-TX, según la tarjeta de red.

3.1.3 INSTALACIÓN DEL CLÚSTER OPENSSI

El proceso de instalación fue dificultoso al inicio, principalmente por lo incompleto y esparzo que resultó ser la documentación oficial [SSID11]. Es bastante aconsejable estar muy bien familiarizado con la distribución que se estará utilizando, en este caso en particular Debian Lenny, de modo que se puedan investigar y solventar los posibles problemas.

En un entorno OpenSSI debe existir un nodo especial denominado nodo init o master. Éste arranca directamente desde el sistema de archivos raíz. El resto de los nodos arrancan desde la red. Para arrancar los nodos non-init o esclavos por red es necesario Etherboot (definiciones) o PXE (definiciones). Etherboot es software libre y se instala en un medio que permita el arranque, como un CD o un disco duro, o bien se graba en la memoria ROM de la tarjeta de red. La mayoría de las tarjetas de red son compatibles con Etherboot. PXE, por otro lado, se encuentra integrada en algunas tarjetas de red y normalmente se

habilita desde el menú de la BIOS.

Debido a que el propósito principal de este trabajo de tesis, es proveer una guía metodología completa de la instalación del nodo master, agregar nodos esclavos y la instalación del una herramienta web para el monitorización visual del clúster OpenSSI.

A continuación se describirá los procesos para implementar un clúster OpenSSI en una distribución de Debian Lenny con los recursos de hardware disponibles en el C.I.C.F.I.

3.1.3.1 Instalación del Sistema Operativo Debian Lenny

Estas instrucciones asumen que se realizara una instalación limpia del sistema operativo, eso quiere decir que no se estará actualizando o modificando las configuraciones existentes de alguna de las computadoras. Para mas detalles de este proceso, se provee el **Anexo 1. Instalando Debian** en donde se encuentran los pasos para este proceso.

1. Instalar Debian Lenny [IDGN11] en el nodo master. No existe la necesidad de instalar esta distribución en los demás nodos.

2. Es recomendado que se realice la partición del disco duro usando las herramientas que provee durante la instalación. El sistema de archivos recomendado es ext3 debido a su capacidad transaccional. La tabla de particiones debería estar conformada de la siguiente manera: **/boot**, **/swap**, y **/**.

3. Configurar GRUB [GRUB11] como gestor de arranque. OpenSSI no soporta LILO [LILO10]

4. Configurar las tarjetas de red con una dirección IP estática. Tanto la tarjeta

de red para la conexión a una red externa, como la tarjeta de red para la interconexión con los demás nodos. Durante el proceso de instalación del OpenSSI se configurara la tarjeta de red para la interconexión con los demás nodos esclavos.

3.1.3.2 Instalación del OpenSSI

Los siguientes procedimientos son los necesarios para la instalación del kernel de OpenSSI en el nodo master. Estos procedimientos pueden encontrarse detallados en el **Anexo 2. Instalación el nodo init o master**.

1. Agregar las siguientes líneas al archivo /etc/apt/sources.list

   deb http://deb.openssi.org/openssi 1.9.6-lenny-preview openssi extras
   deb-src http://deb.openssi.org/openssi 1.9.6-lenny-preview openssi extras

2. Agregar las siguientes líneas al archivo /etc/apt/preferences

   *Package: **
   Pin: origin deb.openssi.org
   Pin-Priority: 1001

3. Si es necesario, configurar el http proxy.

4. Configurar la dirección IP estatica para la tarjeta de red que servirá de interconexión para los nodos esclavos

   #Setting for the Cluster Interconnect
   allow-hotplug eth1
   iface eth1 inet static
   address 192.168.64.1
   netmask 255.255.255.0
   broadcast 192.168.64.255

5. Ejecutar

   # apt-get update
   # apt-get dist-upgrade

6. Agregar los instaladores necesarios de las tarjetas de red al archive /etc/mkinitrd/modules, los cuales seran usandos durante el arranque de los nodos del cluster.

7. Ejecutar

   #apt-get install openssi

Este comando instalara openssi y creara el primer nodo, init o master, del cluster. Durante la creación del primer nodo, mediante el comando *ssi-create*, aparecerán algunas preguntas relacionadas a las configuraciones del cluster. Para los detalles del mismo, se podrán obtener en la referencia al **Anexo 2. Instalación del nodo init o master**.

8. Reiniciar el nodo master

3.1.3.3 Agregar nuevos nodos

Una vez instalado el sistema operativo en el nodo master, instalado el kernel openSSI en el mismo, se procede a agregar nodos para poder contar con una infraestructura Cluster. Los nodos esclavos son iniciados por medio de un método de inicio por red. Esto evita la necesidad de instalar el sistema operativo y el kernel del openssi en mas de un nodo. Para iniciar por red un nuevo nodo, es necesario que la tarjeta de red de los nodos esclavos soporten PXE o Etherboot. Estos procedimientos pueden encontrarse detallados en el **Anexo 3. Agregar nodos a la infraestructura**.

1. Si la tarjeta de red del nuevo nodo no posee soporte de inicio PXE, es necesario descargar el instalador Etherboot desde la siguiente url http://rom-o-matic.net/gpxe/gpxe-1.0.1/contrib/rom-o-matic/ y generar un CD de inicio.

2. Si el nodo requiere un instalador que no se encuentra dentro del archivo

/etc/mkinitrd/modules (en el nodo master), es necesario agregar el nombre del instalador en ese archivo y luego volver a generar el disco de inicio para que el clúster incluya ese instalador a su lista. Para realizar esto:

#mkinitrd -o <init RD image file> <kernel-version>
 # ssi-ksync

3. Conectar el nodo esclavo al switch conectado al clúster, insertar el CD de inicio previamente grabado e inicio el nodo. El CD mostrara la dirección MAC del nodo esclavo y espera un tiempo buscando un servidor DHCP que pueda responderle.

4. En el nodo master ejecutar el comando *ssi-addnode –hwaddress="*MAC_ADDRESS*"* en donde MAC_ADDRESS es la dirección MAC del nodo esclavo. Esto hará que el proceso de agregado de nodos inicie y solicitara las configuraciones, estas se pueden encontrar en el **Anexo 3. Agregar nodos a la infraestructura**.

5. El programa hará todo lo necesario para agregar el nodo al clúster. Es necesario esperar que el nuevo nodo se agregue. Un mensaje de "nodeup" aparecerá en la consola del primer nodo indicando el éxito de la operación. Puede comprobar el estado del clúster por medio del comando *cluster –v*.

6. Si se desea configurar el nuevo nodo como un posible nodo master, y habilitar la tolerancia a fallo (failover), es necesario realizar ciertas configuraciones en el hardware del nodo tales como *ssi-chnode* y configurar las particiones del nuevo nodo así como el sistema de inicio GRUB.

7. Repetir los pasos anteriores cada vez que se desee agregar otros nodos al clúster.

3.1.3.4 Monitorización visual del clúster OpenSSI

Una vez lograda la instalación del nodo master, y agregado nodos esclavos, el siguiente paso es la instalación de la herramienta de monitoreo OpenSSI webView. OpenSSI webView es una herramienta PHP desarrollada por Kilian Cavalotti y extendida por el propio equipo de la tesis. Se encuentra disponible es esta dirección http://darthvinsus.github.com/webview/

La herramienta permite visualizar la carga en cada nodo del clúster, monitorizar el estado de cada nodo y ver las graficas con diversas estadísticas. También es posible monitorizar los procesos en cada nodo y migrar manualmente un proceso a otro nodo. Para utilizar esta herramienta es necesario realizar los siguientes pasos.

1. Extraer directamente en la carpeta del servidor el archivo descargado desde la dirección http://darthvinsus.github.com/webview/

   # cd <DESTDIR>
   # tar xfvj DarthVinsus-webview-1902726.tar.gz

2. Establecer los permisos adecuados en el directorio de gráficos, para la generación de gráficos y la recolección de datos en el archivo config.php, para poder modificar y guardar la configuración desde la interfaz web.

   # cd <DESTDIR>/openssi-webview
   # chown -R <USER> graphs
   # chown <USER> config.php

3. Agregar al cron la tarea de mantener actualizada la interfaz a través de la recolección de datos por medio de un script.

   **/5 * * * * <USER> [-d <DESTDIR>] && (cd <DESTDIR> && ./graphs/update_all.sh)*

4. Habilitar la migración de nodos por medio de la interfaz web, para ello

modificar el archivo *etc/sudoers* y permitir la migración de procesos a todos los usuarios.

<USER> ALL = NOPASSWD:/usr/bin/migrate

Una vez realizado los pasos, acceda desde algún navegador web de su preferencia a la dirección *http:/IP_NODO_MASTER/webview*, donde IP_NODO_MASTER es la dirección IP del nodo master, configurado en la sección

3.2 CONSIDERACIONES DE BENCHMARK PARA EL PRESENTE TRABAJO.

Se definió como objetivo el análisis del comportamiento de un banco de datos sobre una infraestructura SSI.

Debido a falta de un benchmark que realice todas las validaciones necesarias para una infraestructura SSI se requirió del uso de benchmark sintéticos para evaluar los componentes. Con el montado del Banco de Datos se presentó la posibilidad de utilizar un benchmark de Aplicación que simule el trabajo real en una misma operación de banco de datos sobre un sistema SSI.

Considerando el benchmark a ser utilizado, se optó por un aplicación basada en uno de los estándares propuesto por entes reconocidos, logrando de esta manera tener referencia de las medidas ya publicadas por estos entes.

Caracterización de la Carga.

Las prestaciones de todo sistema se orientan según el tipo de trabajo o acciones para el cual se destinan, de esta manera, un sistema utilizado para simulaciones no posee las mismas características que un sistema transaccional de Débito - Crédito. Al trabajo de realizar el modelo representativo que simula una carga futura se le llama Caracterización de la Carga

Con el objetivo de caracterizar el uso de la infraestructura SSI, esta caracterización de carga se dividió en dos tipos según la manera de interactuar con el banco de datos: Transacciones OLTP y Consultas OLAP.

3.2.1 BENCHMARKS OLTP

Debido a las limitaciones económicas y del propio trabajo de tesis, el cual requiere que sean Benchmark de Aplicación Libre para transacciones OLTP se optó por la utilización del estándar TPC debido a su continuidad de los proyectos y a la utilización del mismo por entes de trayectoria [DONG97].

Las Implementaciones TPC son de dominio público, pero no existen muchas aplicaciones de uso libre que ayuden a utilizar de manera rápida este estándar, ya que mayormente son iniciativas de empresas privadas que utilizan para fines particulares.

3.2.1.1 TPC: The Transaction Processing Performance Council

El Transaction Processing Performance Council (TPC según sus siglas en ingles) es una organización sin fines de lucro destinada a definir procesos transaccionales y Benchmark de Banco de Datos para determinar de manera confiable el manejo de datos óptimo en la industria para condiciones de rendimiento.[TPCC11]

No existe una aplicación estándar provista por el consorcio de TPC, pero permiten que las empresas realicen implementaciones siguiendo el estándar para la realización de pruebas de rendimiento. Esta característica fue adoptada a finales de los años 80 cuando existían benchmark como TP1 [GRAY05] y Débito - Crédito [ZHOU99], que no era regulados por un ente y por ende emitían información con falta de veracidad, debido a publicaciones de empresas productoras de servidores. De esta forma se genero el primer benchmark basado en el consorcio TPC conocido como TPC-A, cuyas características reforzaban las reglas Atomicidad, Consistencia, Aislamiento y Durabilidad de transacciones al igual que la posibilidad de ejecutar en redes locales así como también en otras estructuras de red. Posteriormente se genero el estándar TPC-B, que fortaleció las características iniciales del TPC-A y agrego el uso de terminales simulando una situación aun más real del uso de un servidor en un ambiente cliente/servidor.

El propósito del Consorcio se definió de esta manera en los años 90 generando marcas de rendimiento de transacciones de base de datos, consumo de energía y otros. [SHAN98]

El consorcio TPC provee una expectativa de Precio/Rendimiento. Además, tiene extensiones encargadas de proveer información acerca del Consumo de energía [TPCE10]

Estándar TPC-C

El benchmark basado en el estándar TPC-C es una carga de trabajo de Procesos de Transacciones En Línea (OLTP, por sus siglas en Ingles Online Transaction Process) creado por el consorcio TPC. Es un conjunto de transacciones de lectura, inserción y actualización que simulan actividades OLTP complejas.

En TPC-C se utiliza al Rendimiento de trabajo para medir el número de órdenes o solicitudes de trabajo procesadas por minuto. La métrica utilizada es la de transacciones por minuto (tpmC).[TPCC11]

Para un mejor estudio el consorcio TPC dividió en clausulas que son expuestas como sigue:

Diseño Lógico de la Base de Datos:

Sección que define el entorno de aplicación y Negocio, la especificación de entidad, relación y característica de la Base de datos, junto con la disposición de tablas. Además cuenta con reglas de implementación, integridad y el manejo del acceso transparente de datos.

El estándar TPC-C establece una serie de transacciones que son pensadas para suponer que se trata de una empresa en la cual se desempeña la adquisición de productos. [LIMA09]

El modelo que es inicialmente representado en el benchmark presenta a una empresa de ventas con almacenes (del Ingles Warehouses) geográficamente distribuidos manejando el concepto de Departamentos o Distritos (del Ingles

District). De esta manera cada Warehouse puede tener como máximo 10 District y este a su vez solo puede dar atención a 3000 Clientes por District.

Los almacenes tienen un Stock de 100000 productos que son vendidos por la compañía. [TPCC11].

En la Fig. 1 se presenta la esquematización provista por TPC-C de manera a visualizar el negocio.

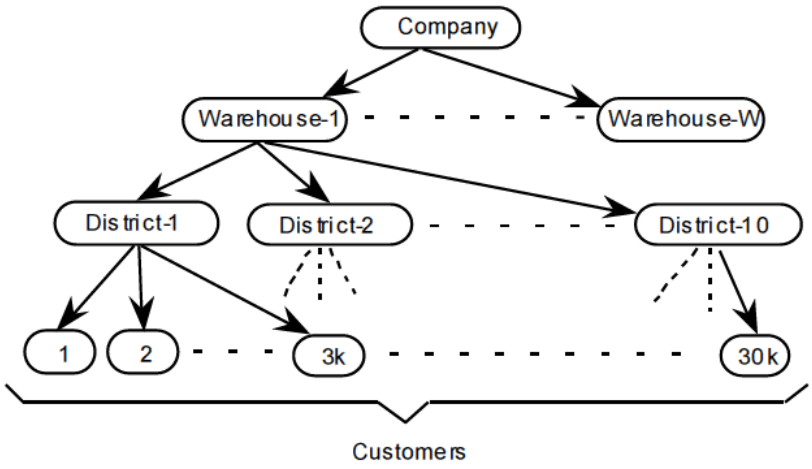

Fig. 1: Diagrama de Esquematización de una Compañía considerada por el estándar TPC (fuente propia)

Acompañando se encuentra la Fig. 2 que presenta las relaciones entre tablas considerada para la aplicación del estándar TPC-C.

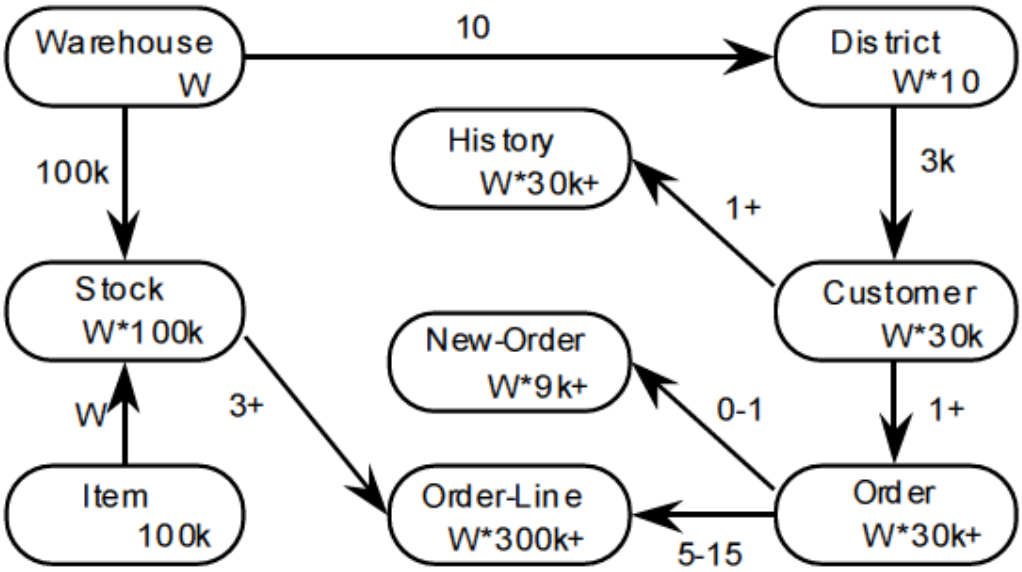

Fig. 2 Diagrama de relaciones entre tablas según el estándar TPC (fuente propia)

Perfil de Terminal y Transacciones

Sección que define los requisitos de Entrada y Salida de terminal. Los requisitos generales para perfiles de transacciones son sub divididas en:

Transacciones de Solicitud de Orden o New Order Transaction

Consiste en una transacción en la cual se ingresa una orden al esquema, es una transacción de alta frecuencia y de coste medio para la estructura debido a su lectura-escritura de datos.

Transacciones de Pago o Payment Transaction

Consta de una transacción que interactúa con el estado de cuenta del cliente, refleja el pago de una solicitud y representa un costo bajo para la estructura debido a las entidades que afecta. Esta transacción tiene una frecuencia alta de ejecución.

Transacciones de Estado de Orden o Order Status Transaction

Consiste en una consulta de la situación actual del cliente, representa una

exigencia de nivel medio a la estructura debido a que es de solo lectura y mantiene una frecuencia baja de ejecución.

Transacciones de Envío o Delivery Transaction

Consta en la agrupación del envío de los productos solicitados. Esta agrupación se realiza cada 10 ítems y son enviadas de forma batch. Corresponde a un proceso de baja frecuencia y manteniendo una lectura-escritura de datos.

Transacciones de manejo de Stock o Stock-Level Transaction

Consta de una operación de variación de ítems en los almacenes; si bien es de baja ejecución requiere un alto costo computacional.

Propiedades del Sistema y Transacciones

Sección que define de manera generalizada las consideraciones ACID (por sus siglas del Ingles Atomicity, Consistency, Isolation and Durability) para el manejo de transacciones.

Escalado y Población de Base de Datos

Sección que define las reglas de ampliación de la base de datos y su vez la población de datos requeridos como mínimo para ser considerados.

Métricas de Rendimiento y Tiempo de Respuesta

Sección en la cual se define las métricas a ser consideradas por el consorcio TPC para considerar un rendimiento y un tiempo de respuesta optimo

SUT, Drivers y definiciones de Confirmación

En esta sección se define acerca de del Sistema bajo Prueba SUT (por sus siglas en Ingles System under Test), Drives Externos que son Provistos por emuladores de terminales externas conocidas como RTE (del Ingles Remote Terminal Emulator) y son usados para emular la carga de trabajo que pueden

realizar los usuarios.

Metodología de Precio

Inicialmente el estándar TPC trata de realizar un cálculo precio/rendimiento de manera a demostrar el rendimiento según los costos del sistema a adquirir. En esta sección define como reportar y realizar este cálculo para publicaciones en el sitio de TPC.

Entre los aplicativos de uso público se encuentra una interesante opción desarrollada por catedráticos de la Universidad de Valladolid [TUVA02] conocido como TPCC-UVA que maneja los cálculos de Transacciones por minuto (tpmC) sin soporte a cálculos de costo - rendimiento (price/tpmC) [TUVA02]

3.2.1.2 TPC-C UVA

El Benchmark TPC-C UVA es una implementación libre, bajo licencia GPL [GNPL07], del estándar TPC-C para medir sistemas OLTP. Fue concebido en el seno de la Universidad de Valladolid y es utilizado en la actualidad para medir ambientes de alto rendimiento, pero con la característica que también funciona de manera optima para ordenadores monoprocesadores.[TUVA02][XIAO06]

El esquema de TPC-CUVA fue desarrollado ampliamente en C considerando como banco de datos a Postgres SQL[HILL06] y el uso de un monitor de transacciones (TM por sus siglas en ingles de Transaction Monitor) libre para resguardarse bajo la licencia GPL.

Entre las características principales del TPC-C UVA se encuentra el estricto control de los requisitos del estándar TPC y el desarrollo en C del TM que permite que este benchmark sea ejecutado prácticamente en cualquier sistema operativo basado en Unix. Aun considerando la restricción que fue desarrollado para Banco de Datos en Postgres es una herramienta potente debido a que la aplicación simula un comportamiento deseando al momento de ejecutar las pruebas. [LIMA09]

Opciones de la Suite TPC-C UVA

La aplicación generada por los catedráticos de la universidad de Valladolid consta de un menú textual que inicialmente provee los ítems necesarios para la elaboración del entorno de pruebas.

Respetando el esquema de la compañía propuesto por TPC el benchmark TPC-C UVA en su primera Opción genera una base de datos completa con un máximo de hasta 100 Warehouse con aproximadamente 138 megabytes de espacio por cada uno. Este proceso genera todo el esquema necesario para la elaboración de las pruebas. [CARRA08]

Luego de Generar el banco de datos con la cantidad de Warehouses deseado la aplicación de TPC-C UVA presenta un menú con las próximas posibles acciones a ser tomadas (Fig 3).

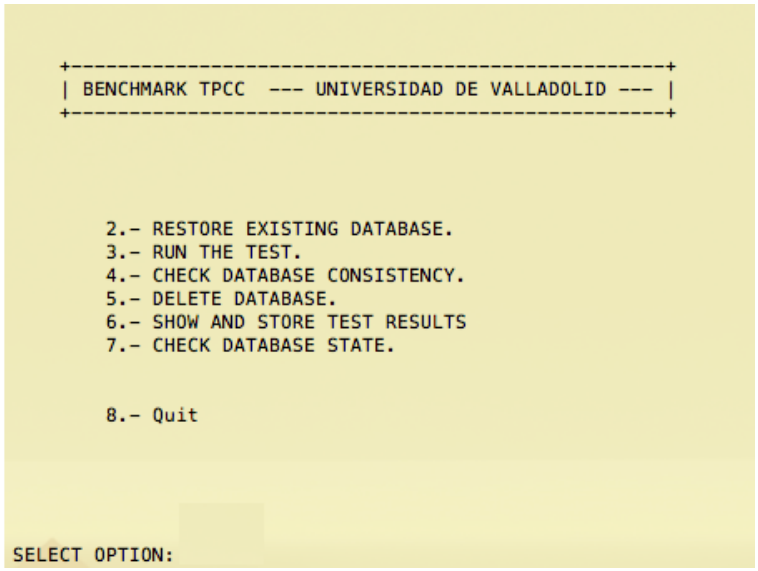

Fig. 3 Menu de opciones del Bench TPC-C UVA

Acerca del Uso de TPC-C UVA

Opción 1 - Creación de una Nueva Base de Datos: Esta opción genera una nueva base de datos acorde al estándar TPC. El numero de Warehouse puede variar entre uno a cien y utiliza el directorio especificado en la instalación como directorio de creación. Se debe tener en cuenta que cada almacén de datos posee aproximadamente 137 megabytes de espacio necesario.

Opción 2 – Restauración de la Base de Datos Existente: Esta opción deshace todos los cambios realizados al banco de datos. Es considerado como el nivel inicial de cada ejecución del benchmark.

Opción 3 – Ejecución del Test: Es la opción principal de la Aplicación. Esta ejecuta el test en la base de datos creada o restaurada. Para la ejecución del test se establecieron parámetros que son solicitados en cada ejecución del test y

son detallados a continuación:

Numero de Warehouse: Se indica cual es el numero de Warehouse a utilizar, Si bien tenemos N almacenes es posible utilizar x Almacenes (donde 0 < x <= N)

Número de Terminales por Warehouse: Si bien el estándar TPC establece de manera inicial 10 terminales, mediante este valor se puede personalizar la cantidad de terminales que realizaran el test. Cada Terminal es un proceso que de manera independiente realiza la ejecución del test sobre cada Warehouse.

Periodo de Ramp-Up: es considerado el tiempo promedio en el cual el sistema se mantiene estable. Según la definición inicial el periodo de estabilidad del benchmark se encuentra aproximadamente en 20 minutos.

Periodo de Medida: Es el parámetro que configura el tiempo de en el cual se ejecutara el benchmark. Según el estándar TPC este se encuentra entre 120 y 480 minutos

Luego de detallar los parámetros iniciales la aplicación consulta si se desean realizar mantenimientos periódicos de los recursos a ser utilizados. Estas opciones permiten configurar el periodo de realización de mantenimientos así como el número máximo de mantenimientos a ser realizados. Para la prueba máxima de 8 horas se recomienda limpiezas cada 60 minutos y como máximo 6 en la ejecución.

Opción 4 – Constatar la consistencia de la Base de Datos: Esta opción realiza verificaciones constando que se realizan las 12 condiciones necesarias de consistencia de base de datos definido en el estándar TPC en su Capitulo 3.

Opción 5 – Eliminación del Banco de Datos de Prueba: Permite indicar al usuario que se desea eliminar el banco de datos.

Opción 6 – Verificación y almacenamiento de Resultados: Esta opción verifica los estados temporales del test realizado. Define si el banco de datos aprobó los valores mínimos de estándar TPC para banco de datos.

Opción 7 – Verificación del estado de la Base de Datos: Esta opción presenta al usuario de la aplicación constatar cuantos registros existen en el banco de datos de manera verificar el funcionamiento de la aplicación.

Opción 8 – Salir: Opción que finaliza la aplicación TPC-C UVA

3.2.2 BENCHMARKS OLAP

Con el fin de abarcar todas las aristas del análisis de rendimiento de base de datos fue necesario optar por una opción que cubra las expectativas OLAP. Así como la implementación TPC-C UVA se encargó de medir de forma explicita el comportamiento OLTP, el consorcio TPC provee un estándar para OLAP llamado TPC-H.

3.2.2.1 TPCh

El TPC-H es un benchmark de aplicación que nació como sucesor del TPC-D, el cual en 1999 fue dividido para dar paso a TPC-R para verificaciones de reportes y TPC-H.

El Benchmark TPC-H trabaja sobre consultas realizadas de manera directa al Banco de datos, de forma tal que no puedan ser optimizadas por el Administrador de Base de Datos o DBA (por sus siglas en ingles de Data Base Administrator) y cuyo esquema de base de datos se encuentre normalizado en la 3ra forma normal. [POESS00]

Las consultas seleccionadas para la ejecución del Benchmark TPCH tienen las siguientes características:

- Alto grado de complejidad.
- Variedad de accesos utilizados.
- Son de carácter ad hoc.
- Abarcan un amplio porcentaje de datos disponibles.
- Todas las consultas difieren entre sí.

- Contienen consultas parametrizadas que varían durante la ejecución.

Para un mejor estudio el consorcio TPC dividió en clausulas que son expuestas como sigue:

Diseño Lógico de la Base de Datos.

Al igual que en el TPC-C, esta es una sección que define el entorno de aplicación y negocio, la especificación de entidad, relación y característica de la Base de datos.

El estándar TPC H establece una serie de consultas que son pensadas para suponer que se trata del estudio posible para cualquier modelo de empresa.

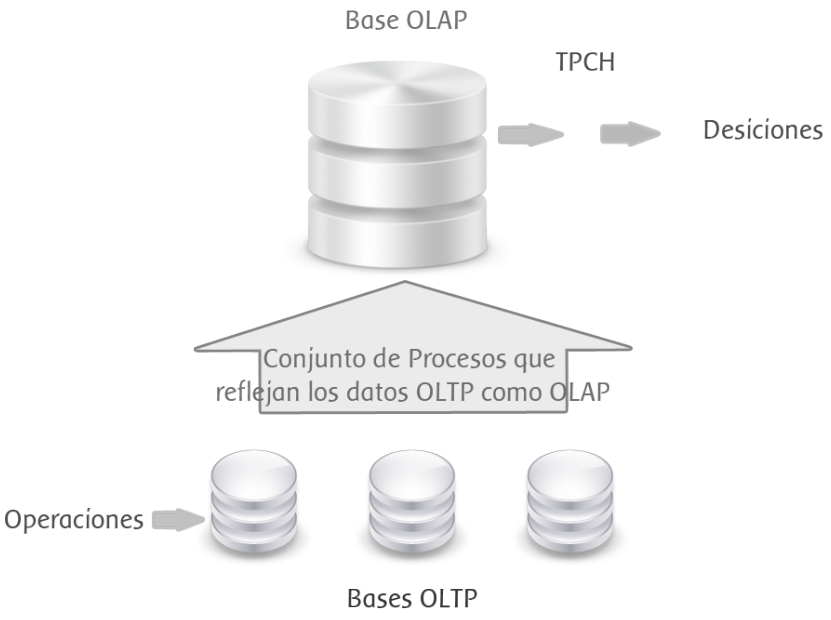

Fig. 4 Diseño lógico de la base de datos

El modelo presentado inicialmente por el estándar TPCH muestra como las operaciones realizadas de manera periódica en las bases OLTP, luego de un conjunto de procesos pasan a ser objeto de estudio en la base de datos OLAP

para la toma de decisiones.

Análogamente al sistema TPCC, el sistema requerido por el estándar TPCH genera entidades y relaciones basados en la tercera forma normal y esquematizado como se muestra en la fig. 5 [POESS00].

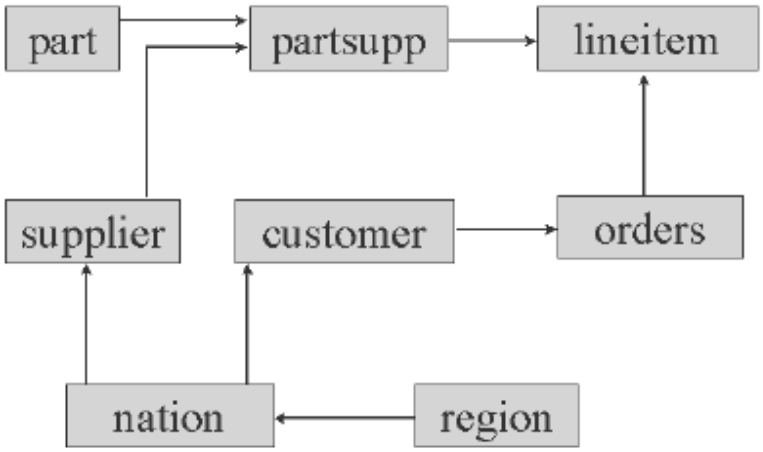

Fig. 5 Entidades y Relaciones para TPC-H

Consultas y funciones de actualización.

En esta sección se definen 22 consultas y entre ellos 2 funciones de actualización que pueden ser ejecutadas por parte en las pruebas TPCH.

Cada una de las consultas están caracterizadas por:

- Ilustrar las preguntas que normalmente se realizan en el transcurso de las toma de decisión.

- Estar definidas según el estándar SQL-92 para poder ser medida por consulta en caso de ser necesario.

- Tener parámetros de sustitución que son descriptos para obtener los

resultados

- Validar las consultas en bases aptas para este tipo de operaciones

Propiedades ACID (Atomicity, Consistency, Isolation, and Durability):

En esta sección se define el uso de las propiedades ACID para mantener la consistencia del banco de datos a lo largo del periodo de test.

Escalado y población de la base datos.

En esta sección se definen las clausulas de escalado del banco de datos, así como también cuales son las medidas de población aceptadas por el estándar

Métricas de performance y reglas de ejecución.

En esta sección se definen los componentes del benchmark, las reglas a ser consideradas para la ejecución y configuración así como las métricas definidas por el estándar en sus clausulas.

Sistema bajo Test (SUT) e implementación de drivers.

Sección que define el manejo de los controladores en los posibles escenarios en los cuales el benchmark puede actuar.

Metodología de Precio.

Como el estándar TPCH intenta medir el precio de Transacciones por minutos realizadas en el control del soporte de decisiones (TpmH) define en esta sección políticas para la toma de resultados

3.3 CARACTERIZACIÓN DE PRUEBAS.

Se conoce como Caracterización de Pruebas a la definición de variables y métricas a ser considerados en la ejecución de los test de Carga. De manera a facilitar su comprensión se encuentra organizada como sigue:

3.3.1 DEFINICIÓN DE MÉTRICAS PARA LA CUANTIFICACIÓN DE RENDIMIENTO.

La noción de rendimiento engloba muchos conceptos y para ello es necesario definirla. De manera a orientar Rendimiento junto con carga de trabajo damos énfasis a las siguientes definiciones:

3.3.1.1 Definición de valores para factor de Comparación.

Para cada métrica considerada como medida de rendimiento debe necesariamente existir un valor comparativo, que denote el éxito o fracaso de la evaluación mediante Benchmarks. Para ello existen dos posibilidades de evaluar mediante:

La aplicación de Benchmark a Mainframes:

Actualmente en la página oficial del Benchmark existe publicaciones de pruebas realizadas a mainframes con distintas tecnologías y motores de base de datos publicadas por empresas privadas. [DONG97]. Este listado agrupa año tras año desde 1986 a las arquitecturas mas resaltantes en cuanto a desempeño, englobando la disponibilidad adquirida mediante los sistemas de Procesamiento Paralelo Masivo (MPP por su siglas del ingles Masive Parallel Processing) y la estabilidad obtenida con los sistemas de Multi Procesamiento Simétrico (SMP por su siglas del ingles Symetric Multi Processing). Como criterio para medir el rendimiento se utiliza el mejor rendimiento obtenido por el Benchmark LINPACK [LINP08] que es una colección de subrutinas de Fortran que analiza y resuelve ecuaciones lineales para obtener el tiempo de proceso.

El equivalente para la utilización de las librerías de Linpack es una interface en C llamada Lapack [LAPA11] que provee los medios necesarios para utilizar ampliamente estas librerías.

La comparación contra valores estándares del Benchmark:

Para tener un punto de comparación de valores base se realizó una prueba en un ordenador no perteneciente a un entorno de clúster con aplicativos mínimos que plasmen el funcionamiento del benchmark para ordenador como punto de comparación.

El factor de comparación fue de Transacciones por minutos (tmpC) considerando esta medida como la utilizada por el Consorcio de TPC y corresponde a la medida para medir el Troughtput.

3.3.1.2 Definición de las pruebas.

De manera a definir las pruebas realizadas se separan los conceptos y consideraciones a tener en cuenta.

Consideraciones de limitaciones de eficiencia.

Entrada y Salida (I/O por sus siglas del ingles Input Output): es considerado como la mayor limitación de eficiencia en los banco de datos debido a que el acceso y lectura a discos de almacenamiento es más lento que el acceso a memoria dinámica.

Utilización de Consultas Ad hoc: Son consultas no repetitivas utilizadas para las pruebas OLAP, al no ser reutilizadas el cache debe ser siempre vaciado para volver a consultar.

Normalización de Datos para consultas OLAP: un requisito de la ejecución de benchmark OLAP es que las tuplas sean des normalizadas ocupando un mayor

espacio en disco.

3.3.1.3 Aplicaciones a ser utilizadas

En el marco del desarrollo de las pruebas se definen las herramientas según el tipo de análisis a ser realizado:

Transacciones OLTP: Se realizan transacciones OLTP según el estándar TPCC con la utilización del TPCC-UVA. Los resultados son generados por la aplicación. Los gráficos según los resultados obtenidos se generan con el programa GNUplot [BRAG03] una herramienta bajo licencia GPL.

Consultas OLAP: Se genera los datos utilizando el programa provisto por el consorcio TPC llamado DBGEN [DBGE00]

3.3.1.4 Descripción de SUT (Sistema bajo Pruebas del ingles System Under Test):

Para la ejecución de los test se definen los siguientes objetos de estudio:

Nodo simple: Ordenador estándar con características mínimas similares a los ordenadores que pueden obtenerse en el mercado.

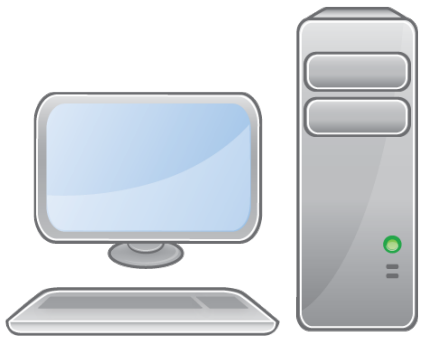

Fig. 6 Nodo Simple

Clúster de dos Nodos: Consta con la mínima cantidad de nodos para ser considerado un clúster. Se considera como un clúster homogéneo debido a que tanto el nodo maestro como el nodo esclavo poseen las mismas características entre sí.

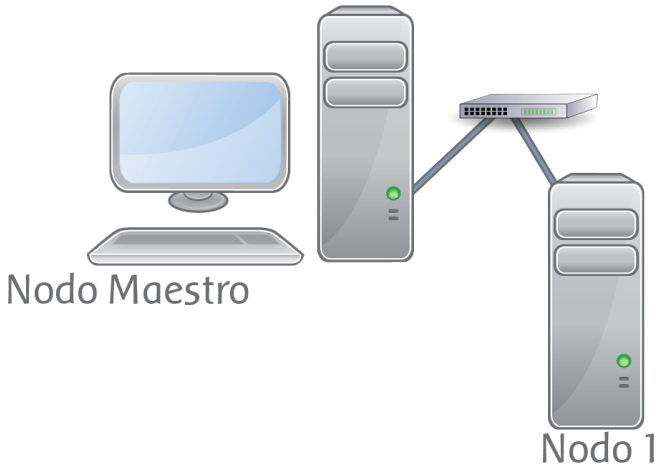

Fig. 7 Cluster de 2 nodos

Clúster de Tres Nodos: Consta de tres nodos homogéneos similares al nodo simple.

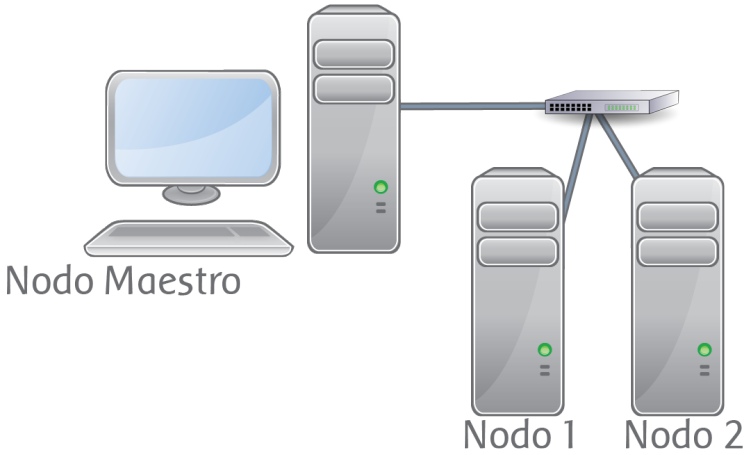

Fig. 8 Cluster de 3 nodos

Clúster de Cuatro Nodos: Se incrementa la capacidad del clúster de tres nodos mediante la adición de un nodo mas, similar a los anteriores para mantener la homogeneidad del clúster de forma tal de proveer tolerancia a fallos.

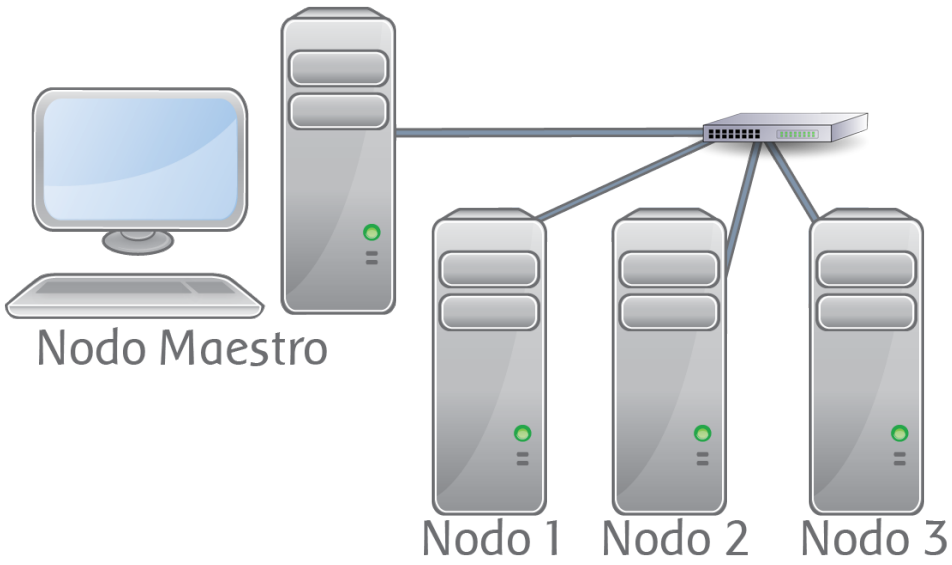

Fig. 9 Cluster de 4 nodos

Debido a que tanto el nodo simple, como los nodos componentes de cada uno de las estructuras poseen las mismas características, se engloban las características de en este apartado.

3.3.1.5 Especificación técnica de los componentes:

Procesador	AMD Athlon(tm) Processor LE-1640 Processor Speed: 2.6 GHz. L2: 1 MB.
Memoria (RAM):	3 GB DDR-2 800 MHz.
Disco Duro (Hard Disk):	250 GB, SCSI de 15,000 rpm.

Placa Madre (Motherboard):	ASUSTeK Computer INC. M2N-MX SE Plus System Bus Speed: 800 MHz. System Memory Speed: 667 MHz.
Tarjeta de Red	Intel (R) Pro/100 Network Conecction Fast Ethernet

3.3.16 Sistema Operativo Utilizado

Se opto por un sistema operativo libre de la distribución libre de Linux conocido como Debian en su versión 5 (Nombre Clave Lenny) [IDGN11] debido a su estabilidad. Acerca de la especificación técnica y los instructivos de instalación se encuentra en el Anexo 1. Instalación del Sistema Operativo Debian Lenny

3.3.1.7 Topología de Red utilizada

Debido a la limitación del uso de elementos existentes en el Centro de Investigación de la Facultad de Ingeniería se opta por una topología de red del tipo estrella [MENE05] mediante un concentrador de paquetes.

3.3.2 METODOLOGÍA DE EVALUACIÓN CON RESPECTO A LOS COMPONENTES

La obtención de resultados fiables que requieran la aplicación de una cantidad de pasos dispuestos de forma tal, que los resultados obtenidos sean siempre comparable entre ellos.

El objetivo de esta sección es presentar la metodología utilizada en los análisis de los Sistemas Bajo Prueba (SUT).

3.3.2.1 Objetivo de Prueba

Las pruebas consistieron en ejecutar los diferentes test de pruebas en diferentes SUT, es decir, la misma prueba fue ejecutada en cada uno de los entornos.

3.3.2.2 Tamaño del Banco de Datos

De manera definir un tamaño a ser utilizado se contempló para cada uno de los tipos de pruebas valores diferentes definidos a continuación;

Pruebas OLTP

Se utilizó un máximo de 10 Warehouse el cual en promedio posee 137 megabytes por almacén, es decir, que en su totalidad conforman 1,33 Gigabytes.

Pruebas OLAP

Se utilizó una base promedio con 100 gigabytes de Datos, considerado así por el estándar TPCH.

3.3.2.3 Periodicidad de las Pruebas

Como los objetos de Prueba se basaron en dos formas diferentes de interactuar con la información se definió la periodicidad en dos tipos de pruebas:

Pruebas OLTP

Con el fin de establecer un tiempo estándar se tomaron 3 tiempos diferentes de pruebas con una unidad de medida en minutos, definidos como siguen:

1. **Prueba de Dos minutos:** esta prueba consistió en que el periodo de medida sea de dos minutos (2 min.) y fue el equivalente a una prueba de valores de tiempo mínimo. Para ello se utilizó un tiempo de Rampa de Un minuto debido a que es el mínimo valor permitido por los benchmark a ser utilizados.

2. **Prueba de Veinte Minutos:** Consistió en un valor aleatorio obtenido mediante un consenso. Para ello se utiliza el valor de Diecinueve minutos (19 min.) de periodo de rampa debido a que es un tiempo cercano al óptimo y en donde la cantidad de Transacciones procesadas por minuto empezó a llegar

al máximo presentado.

3. **Prueba de Ciento veinte minutos:** Consistió en un valor considerado como mínimo optimo por los creadores del TPCC-UVA. Para ello se utilizó un periodo de rampa de Veinte minutos (20 min.) considerado como optimo mínimo según el manual del Benchmark aplicado.

Pruebas OLAP

Con respecto a la ejecución de Pruebas OLAP no se establecieron periodos de pruebas debido a que las pruebas OLAP se basaron en consultas al Banco de Datos y no en Operaciones por minutos.

3.3.3 UTILIZACIÓN DEL BANCO DE DATOS

Debido a la limitación en cuanto al tamaño del disco duro, del nodo simple al ejecutarse las pruebas se manejó la variable de utilización del Banco de Datos, dividido según el tipo de prueba:

3.3.3.1 Pruebas OLTP

En la estructura de Banco de datos se puede limitar la ejecución de pruebas utilizando Almacenes o Warehouse para procesar las transacciones OLTP. Esta fue una característica que no permitió trabajar con todo el banco de datos y no contempló las terminales que se conectaron a esos almacenes. Para ello la división se realizó como sigue:

1. **Utilización de Un (1) Warehouse:** Fue considerado como el valor mínimo soportado por los SUT.

2. **Utilización de Seis (6) Warehouse:** Fue la máxima cantidad de almacenes soportada por un Nodo simple en el cual las pruebas resultaron exitosas. Excediendo este Valor las pruebas no concluyen según verificaciones preliminares realizadas.

3. **Utilización de Diez (10) Warehouse:** fue el estándar considerado por el estándar TPCC como medida optima de TPmC

3.3.3.2 Pruebas OLAP

No existe una limitación con respecto al Nodo simple, por la cual se utiliza la totalidad del Banco de Datos estipulado para este tipo de pruebas (100 Gb).

Repetición de Pruebas

De manera a reflejar resultados obtenidos según el promedio resultante de una serie de ejecución se estableció un valor de ejecución de 5 veces para cada prueba realizada (OLTP y OLAP)

3.3.4 OBTENCIÓN DE RESULTADOS Y CARACTERIZACIÓN DE PRUEBAS

Con el fin de realizar las estadísticas con los resultados obtenidos luego de las pruebas se estableció una metodología de registro de Resultados según el tipo de prueba y definidos a continuación:

3.3.4.1 Pruebas OLTP:

Para el registro de cada prueba se tuvo presente el formulario establecido como estándar por el consorcio TPCC, ver anexo Formulario OLTP de Pruebas, y a su vez fueron registrados los resultados generales de cantidad de transacciones por minutos (TPmC) en la Planilla General de Pruebas, la cual se halla disponible como uno de los anexos a este trabajo.

3.3.4.2 Pruebas OLAP:

Los resultados de los tiempos registrados se encuentran en el anexo de Planilla general de pruebas

De manera a obtener un solo resultado de las pruebas realizadas, se presentó como resultado final el promedio de los valores obtenidos del total de

ejecuciones realizadas por cada tipo de prueba.

3.4 PLANILLA GENERAL DE LOS RESULTADOS

3.5 ANÁLISIS DE RESULTADOS Y GRÁFICOS

En este apartado se exponen los gráficos generados a partir de los resultados obtenidos durante las pruebas. Para una mejor comprensión se decidió separar el análisis, según el tipo de prueba ejecutada, en dos secciones.

3.5.1 TRANSACCIONES OLTP

De manera a contrastar el comportamiento de las transacciones OLTP se presenta un resumen general en la tabla [tabla general de resultados oltp]. En ella se despliegan las transacciones por minutos arrojadas por el benchmark tpcc-uva (TpmC-uva) reflejando su comportamiento ante diferentes situaciones.

Tipos\nodos	1 (seg.)	2 (seg.)	3 (seg.)	4 (seg.)
1-2	16,995	16,499	17,000	16,999
1-20	13,650	13,600	13,650	13,649
1-120	12,500	12,580	12,617	12,292
6-2	64,998	104,443	101,498	101,496
6-20	77,250	78,900	78,850	77,950
6-120	65,850	68,958	75,875	74,292
10-2	78,540	163,540	165,497	160,993
10-20	76,850	128,850	128,300	119,149
10-120	69,042	103,042	108,903	116,842

A modo de permitir una mejor visualización del comportamiento de cada uno de los tipos de pruebas se elaboro un grafico general de rendimiento por nodos. En ella se ilustra el resultado de la conjugación de variables presentadas con anterioridad.

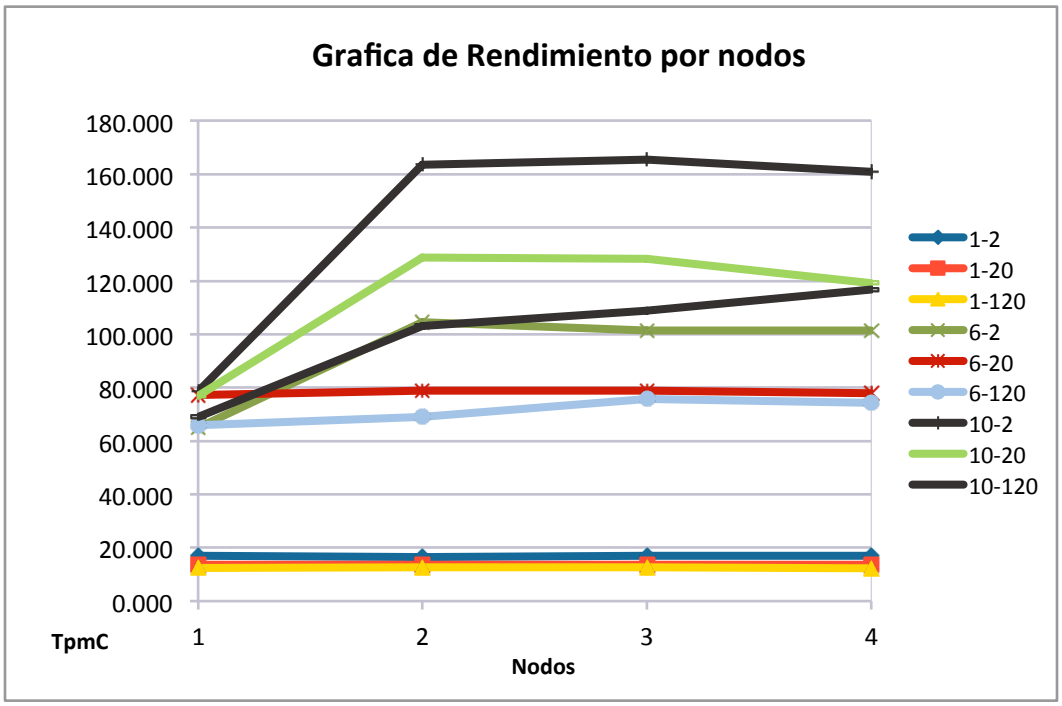

Gráfica 1 Rendimiento por nodos

En la grafica se puede visualizar tres comportamientos bien definidos. Estos comportamientos se relacionan según la cantidad de warehouse utilizados para las pruebas.

Con la intención de plasmar de una manera adecuada el comportamiento de las pruebas se aislaron según la cantidad de warehouse para la presentación del análisis y están definidas como sigue:

3.5.1.1 Pruebas realizadas con 1 (un) Warehouse de Datos:

La agrupación de pruebas realizadas con un warehouse de datos podemos notar que presenta uno de los comportamientos más regulares en cuanto a las transacciones por minuto registradas. Estas medidas se reflejan en la tabla 1.

Tipos\nodos	1 (seg.)	2 (seg.)	3 (seg.)	4 (seg.)
1-2	16,995	16,499	17,000	16,999
1-20	13,650	13,600	13,650	13,649
1-120	12,500	12,580	12,617	12,292

Tabla 1 Pruebas 1 Warehouse

La tabla demuestra que para el valor mínimo de warehouse (w) no existe una variación (v) significante de la línea formada por las intersecciones de TpmC-uva y el numero de nodos. Estos valores fueron obtenidos teniendo como variable el tiempo de ejecución del benchmark y el comportamiento se expresa en la gráfica 2.

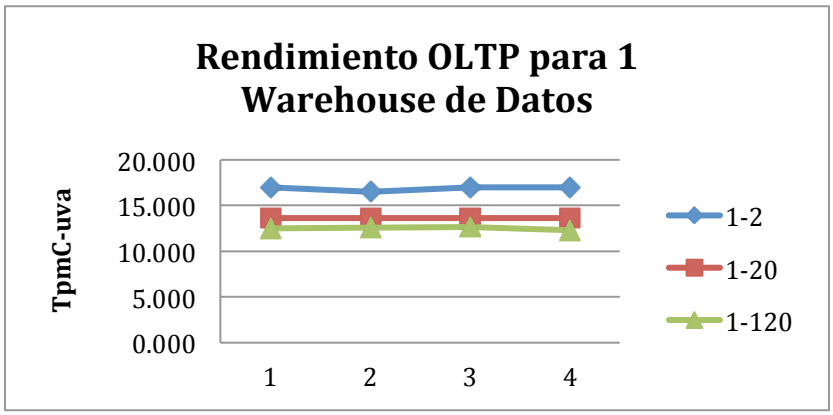

Gráfica 2 Rendimiento OLTP 1 Warehouse

Realizando un análisis de la eficiencia con respecto al nodo principal elaboramos la tabla 2 que expresa los porcentajes de mejora.

Tipos\nodos	%inicial	% mejora	% mejora	% mejora
1-2	0	-2,919	0,029	0,024
1-20	0	-0,366	0,000	-0,007
1-120	0	0,640	0,936	-1,664

Tabla 2 Mejora Rendimiento 1 Warehouse

Como se puede apreciar existe una fluctuación entre el -3% y el 1% de ganancia con respecto al rendimiento del nodo simple. En la grafica 3 se expone la oscilación presentada por los porcentajes de ganancia con respecto al nodo simple.

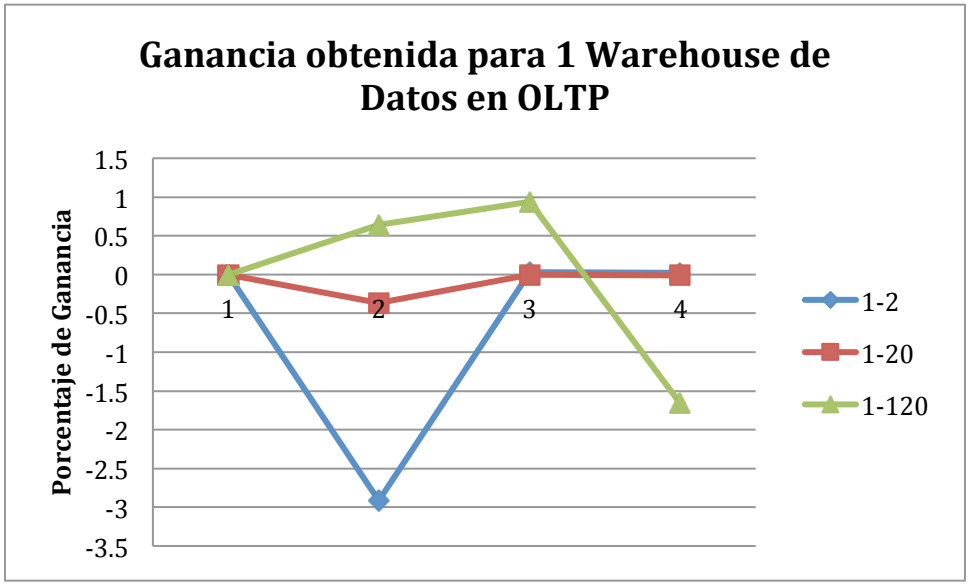

Gráfica 3 Ganancia obtenida en 1 warehouse

Según las evidencias mencionadas pensamos que el comportamiento de la estructura SSI para un Warehouse se debe a que el sistema no realiza un paralelismo en almacenes de datos relativamente pequeños.

Por otro lado podemos resaltar que conforme el tiempo transcurre, disminuye la cantidad del promedio de transacciones realizadas por minuto. Creemos que es debido a que se notaron grandes incrementos de rendimiento en el inicio de las pruebas y luego bajaron de manera a afectar el promedio.

3.5.1.2 Pruebas realizadas con 6 (seis) warehouse de Datos:

La acotación de las pruebas para 6 warehouses de datos presentó un rendimiento superior con respecto a las realizadas con el mínimo de warehouses. Estas apreciaciones son gracias a los resultados plasmados en la tabla 3.

Tipos\nodos	1 (seg.)	2 (seg.)	3 (seg.)	4 (seg.)
6-2	64,998	104,443	101,498	101,496
6-20	77,250	78,900	78,850	77,950
6-120	65,850	68,958	75,875	74,292

Tabla 3 Pruebas 6 warehouse

En la tabla de rendimiento para transacciones OLTP de 6 warehouse de datos corroboramos que los picos máximos de TpmC-uva fueron los registrados durante las pruebas de 2 minutos, acrecentando su in proporcionalidad con respecto al aumento del tiempo. Estas afirmaciones son perfiladas en la gráfica 4.

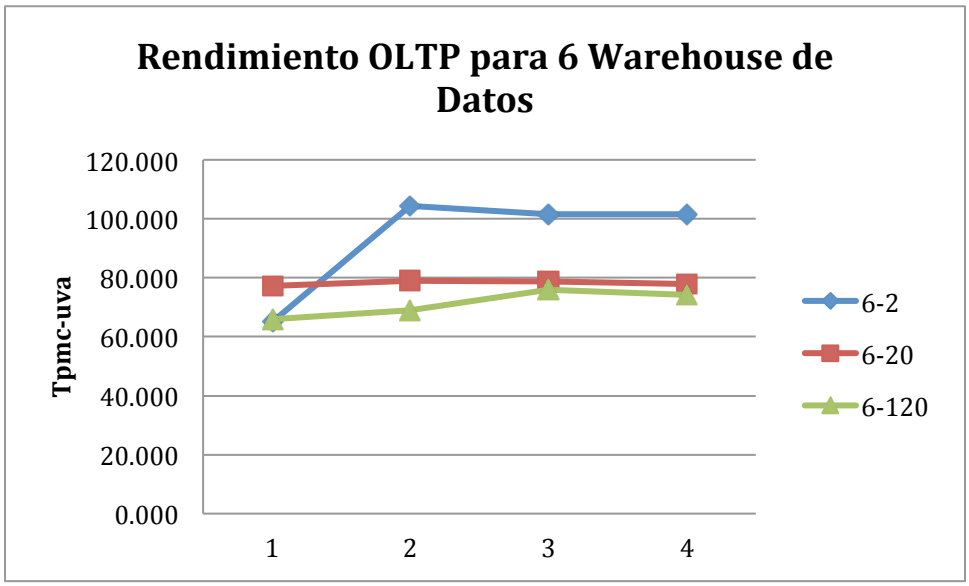

Gráfica 4 Rendimiento OLTP 6 warehouse

Con respecto a la ganancia obtenida durante la adición de nodos se elaboro una tabla 4 que plasma las diferencias.

Tipos\nodos	1(seg)	2(seg)	% mejora	3(seg)	% mejora	4(seg)	% mejora
6-2	64,998	104,443	60,686	101,498	56,156	101,496	56,152
6-20	77,250	78,900	2,136	78,850	2,071	77,950	0,906
6-120	65,850	68,958	4,720	75,875	15,224	74,292	12,820

Tabla 4 Valores TpmC y Mejora Rendimiento 6 warehouse

Omitiendo los valores TpmC-uva previos obtenemos las referencias exclusivas

de ganancias con respecto al nodo simple, tal como se visualiza en la tabla 5.

Tipos\nodos	%inicial	% mejora	% mejora	% mejora
6-2	0	60,686	56,156	56,152
6-20	0	2,136	2,071	0,906
6-120	0	4,720	15,224	12,820

Tabla 5 Mejora Rendimiento 5 warehouse

De esta ultima deducimos que el mayor margen de ganancia se obtiene durante la adición del 2do nodo al sistema para operaciones de corto periodo oscilando entre el 56% y el 61%; y para periodos extensos se visualiza una ganancia max del 15% para el 3er nodo seguida de 12% para el 4to nodo.

A diferencia de las pruebas con un warehouse de datos, las características principales de este grupo muestran el alto número de transacciones realizadas. Creemos que la causa principal es debido al paralelismo realizado por el clúster para un número mayor de warehouse, ya que la pendiente del segmento denotado entre uno y dos nodos es mucho mayor al resto de los segmentos.

Para este caso tenemos un pico elevado de ganancia para periodos mínimos de transacciones teniendo un declive para periodos de 20 minutos e incrementando gradualmente según incrementa el tiempo del periodo de prueba.

3.5.1.3 Pruebas Realizadas con 10 (diez) Warehouse de Datos:

El tercer grupo de pruebas fue utilizando 10 warehouse de datos presentando un comportamiento similar para todas las pruebas en un nodo y teniendo un alto incremento en el segmento indicado por los nodos 1 y 2 tal como lo expresa la tabla 6.

Tipos\nodos	1 (seg.)	2 (seg.)	3 (seg.)	4 (seg.)
10-2	78,540	163,540	165,497	160,993
10-20	76,850	128,850	128,300	119,149
10-120	69,042	103,042	108,903	116,842

Tabla 6 Pruebas 10 warehouse

Esta ultima evaluación supero las expectativas con respecto a las TpmC-uva esperadas por lo visto anteriormente gracias a su comportamiento. En la tabla podemos visualizar que el rendimiento es mayor para operaciones de corto periodo y, en contra partida, para periodos largos el aumento tiende a ser constante a partir del 2do nodo.

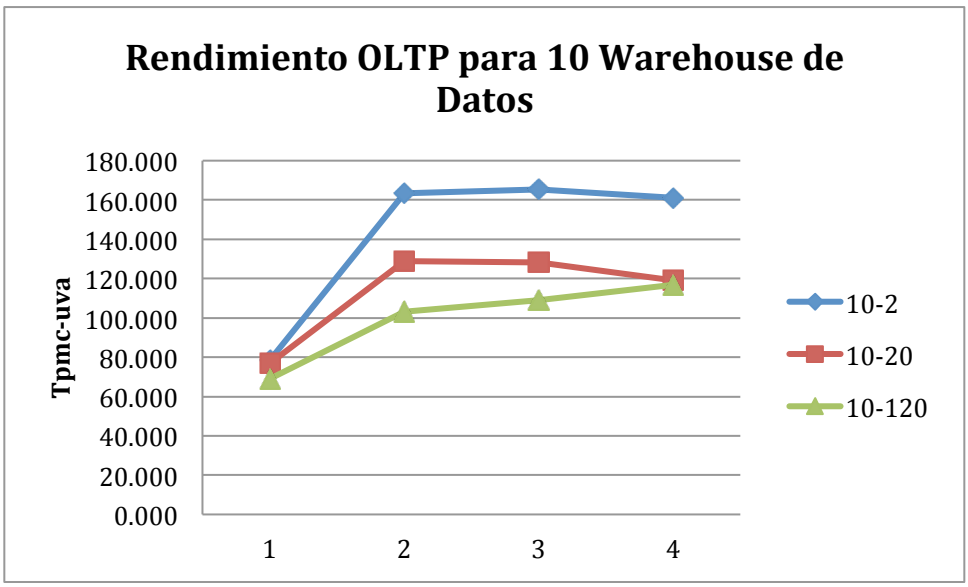

Gráfica 5 Rendimiento OLTP 10 warehouse

Luego de verificar las ganancias expuestas en la grafica 6 podemos notar que existen mejoras del mas del 100% en operaciones de corto tiempo con tendencias a decaer. En cambio para operaciones de mayor tiempo el porcentaje de optimización presenta una pendiente ascendente conforme se agregan los nodos.

Tipos\nodos	%inicial	% mejora	% mejora	% mejora
10-2	0	108,225	110,717	104,982
10-20	0	67,664	66,949	55,041
10-120	0	49,245	57,734	69,233

Gráfica 6 Mejora Rendimiento 10 warehouse

El comportamiento de los porcentajes de ganancia plasmados en la grafica 7 presentan de manera visual las afirmaciones realizadas con anterioridad.

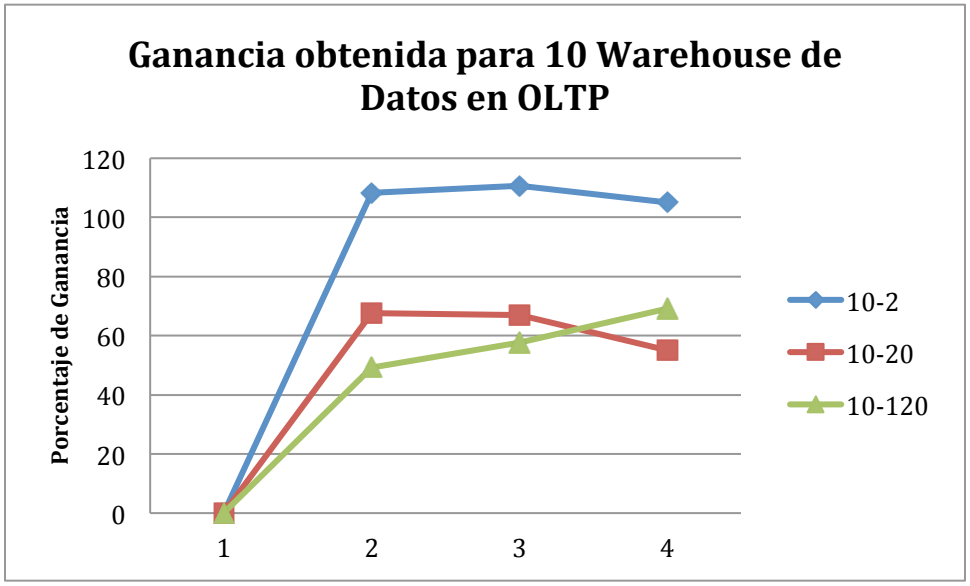

Gráfica 7 Ganancia obtenida 10 warehouse

El aprovechamiento de los nodos para mayores cantidades de warehouse presento los niveles inversamente proporcionales de TpmC-uva con respecto a las pruebas con warehouse mínimo. De esta situación confirmamos que la infraestructura no mantiene el mismo comportamiento inicial a lo largo del tiempo y genera una línea futura de investigación en cuanto a la optimización de TpmC-uva para grandes magnitudes de tiempo. No obstante hemos notado que la ganancia que puede ser obtenida con el incremento de nodos tiende a crecer para operaciones de altos periodo de tiempo.

3.5.2 TRANSACCIONES OLAP

Por otra parte se realizaron pruebas que cubren el procesamiento analítico en línea (OLAP por sus siglas en ingles).

El objetivo de las pruebas OLAP se basaron en verificar el comportamiento de la ejecución de consultas utilizadas en los sistemas de información gerencial en SUT diferentes, conforme se incrementan los nodos.

A modo de resumen general se elaboro el promedio de todas las consultas

OLAP realizadas en los distintos entornos y cuyos datos son expresados en la tabla 7.

Tamaño\nodos	1 (seg.)	2(seg.)	3 (seg.)	4 (seg.)
1 GB	55,774	53,963	36,046	43,119
10 GB	55,476	16,948	11,900	9,361
100 GB	61,584	55,243	17,423	30,744

Tabla 7 Resultados Generales OLAP

De manera a realizar un análisis acerca de este resultado, la grafica 8 muestra un notable optimización de tiempo conforme se aumentan los nodos. Este comportamiento regular de los tiempos obtenidos con el aumento de nodos en el sistema bajo prueba, plasma las mejoras obtenidas principalmente en el segmento denotado entre el 2do y el 3er nodo en donde la pendiente de tiempo es más pronunciada. Además de ello se verifica un leve decremento de rendimiento al agregar el 4to. nodo para los valores máximos considerados.

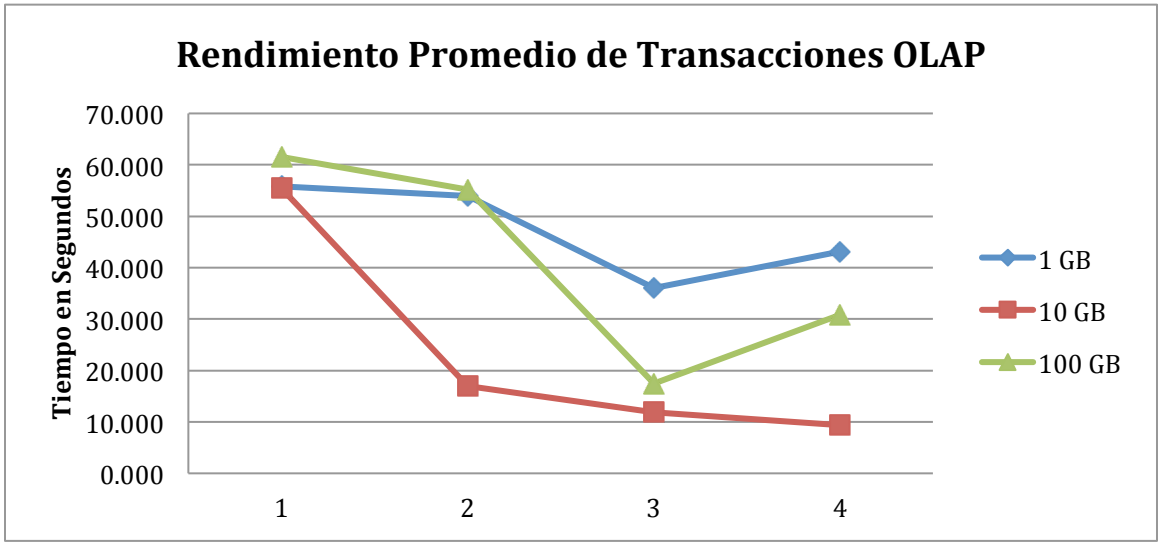

Gráfica 8 Rendimiento Promedio OLAP

La optimización del sistema provee la tabla 8, en la cual se calculan los porcentajes de ganancia obtenida durante el incremento de nodos.

Tamaño\ nodos	1 (seg.)	2 (seg.)	% mejora	% m. total	3 (seg.)	% mejora	% m. total	4 (seg.)	% mejora	% m. total
1 GB	55,774	53,963	3,246	3,246	36,046	33,203	35,371	43,119	-19,622	20,096
10 GB	55,476	53,422	3,703	3,703	11,900	77,725	78,550	9,361	21,338	82,478
100 GB	61,584	55,243	10,296	10,296	17,423	68,462	71,709	30,744	-76,460	44,347

Tabla 8 Tiempo y Porcentaje Mejora OLAP

Si excluimos los tiempos obtenidos y mantenemos los porcentajes, la tabla 8 se puede transformar en la tabla 9, marcando la ganancia obtenida a medida que se agregan nodos.

Tamaño\nodo agregado	2do(%)	3ro(%)	4to(%)
1 GB	3,246	35,371	20,096
10 GB	3,703	78,550	82,478
100 GB	10,296	71,709	44,347

Tabla 9 Porcentaje Mejora OLAP

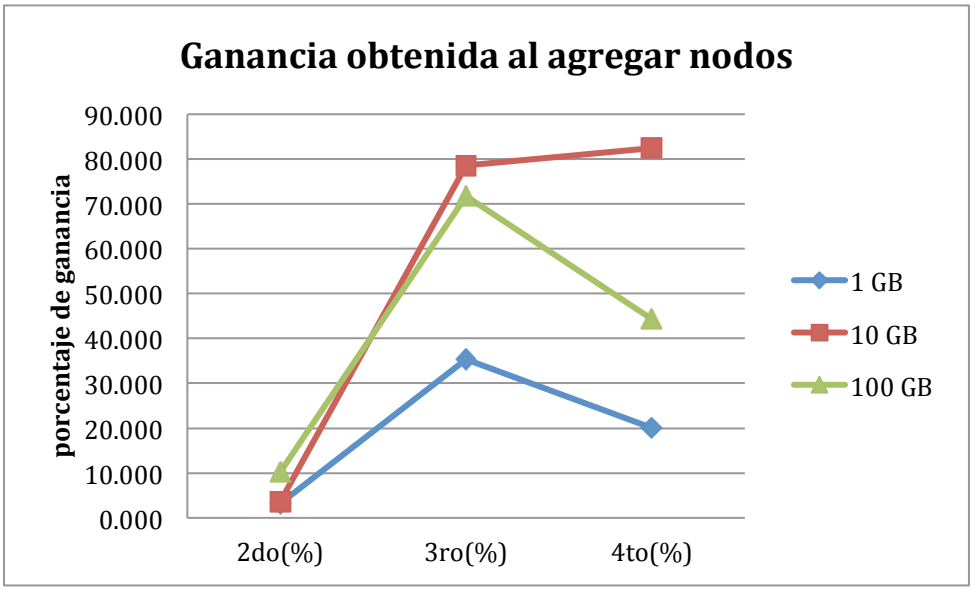

Gráfica 9 Ganancia por nodo agregado OLAP

La grafica 9 queda plasmada en el grafico[nombre del grafico] en el cual se aprecia que, durante la adición del 2do nodo, existe un margen de ganancia del 3% al 10% y alcanzando una optimización, al agregar el 3er nodo, de ganancias

que van desde el 35% al 78%. Durante la incorporación del 4to nodo al sistema notamos un incremento del 20% para el peor caso y del 82% para el mejor caso con respecto al nodo simple.

Las pruebas se comportaron de manea regular según el promedio general obtenido, es por ello que se omite el análisis según el tamaño del banco de datos. Creemos que la razón del incremento del margen de ganancia, se debe a la optimización de carga y memoria brindada al agregar un nodo más a la estructura.

Paralelamente se obtuvo un estado del la estructura capturando en la grafica 10, en el cual notamos el uso de carga y memoria para las pruebas en las que se utilizo solo el nodo 1 y cuál es su reacción al agregarse otro nodo.

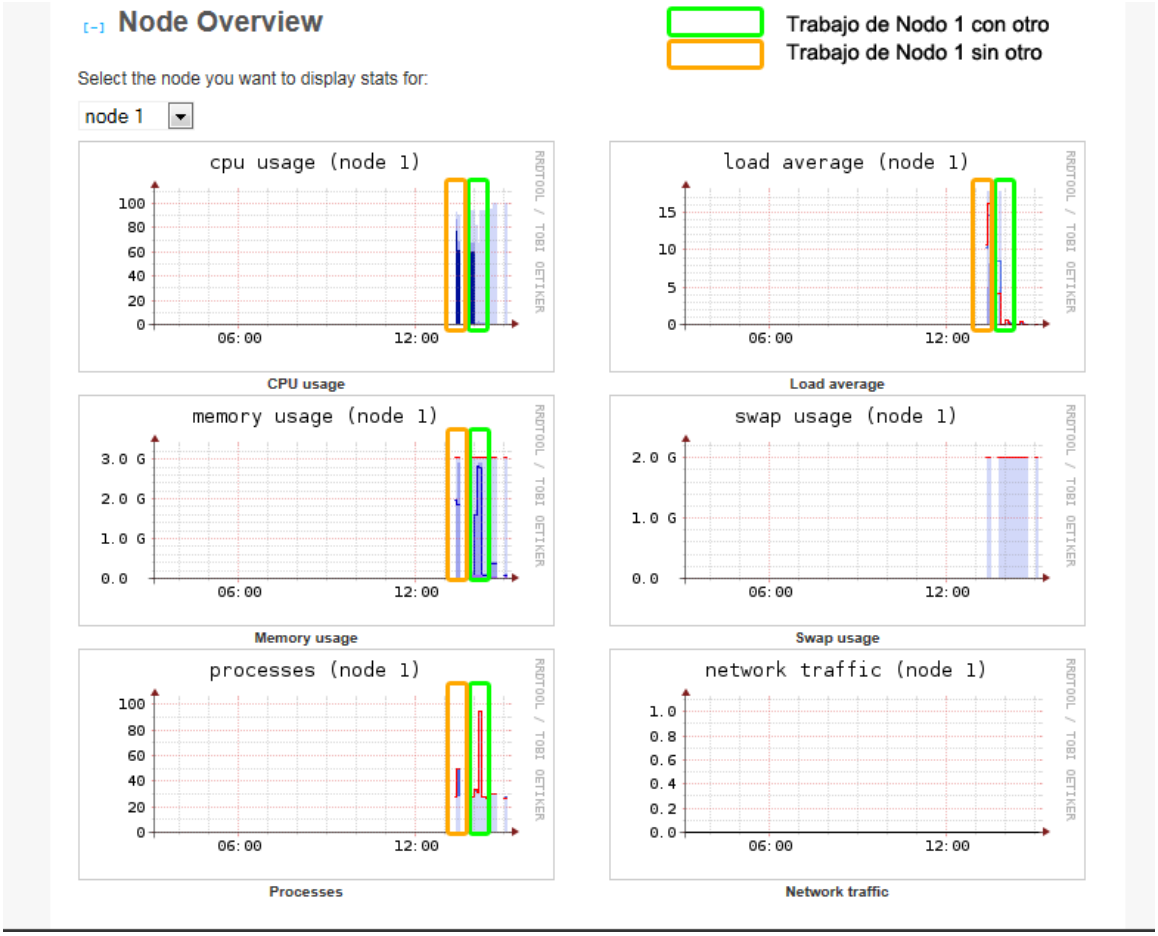

Gráfica 10 Monitoreo 1er nodo

Luego de agregar el siguiente nodo hemos notado que la carga y el uso de memoria también es migrada al nuevo nodo aumentando el rendimiento de la infraestructura como se visualiza en el grafico [nombre del grafico de 4 nodos].

Gráfica 11 Monitoreo 4to nodo

4 CONCLUSIONES Y RECOMENDACIONES

Como culminación del presente trabajo, se presentan en este capitulo las conclusiones finales y son propuestos algunos tópicos como futuras líneas de investigaciones.

4.1 LOGROS CUMPLIDOS

En este trabajo se ha implementado en el Laboratorio del Centro de Investigación en Computación de la Facultad de Ingeniería (CICFI) una infraestructura de altas prestaciones SSI [MORI04] para aplicaciones de banco de datos, como alternativa a la adquisición de costosos Mainframes.

Se ha evaluado el desempeño de la infraestructura mediante pruebas de rendimiento basadas en el estándar TPC [TPCC11]. Estos resultados además sirven como aporte a la comunidad de código abierto del proyecto OpenSSI [WALK05] sobre el comportamiento de la infraestructura ejecutando pruebas de rendimiento TPC-C y TPC-H.

Con los resultados obtenidos se demostró que una infraestructura de altas prestaciones brinda mayor eficiencia que un ordenador de características medias. Si bien las limitaciones con las que se cuenta en el CICFI como trafico de red y uso del espacio físico entre otros, son incidentes directos en la eficiencia de la infraestructura, se ha podido demostrar que con los recursos presentes se ha podido adquirir una infraestructura que provea altas prestaciones a menor coste y manteniendo el nivel de criticidad de los datos establecidos.

Se ha optimizado la infraestructura para la ejecución de Banco de datos mediante ajustes en las configuraciones del middleware SSI. Además el presente trabajo de tesis sirve como guía metodológica de implementación de una infraestructura de altas prestaciones basado en el middleware OpenSSI

[WALK05] y optimizado para la ejecución de aplicaciones de banco de datos.

Hemos ejecutado las pruebas con un clúster OpenSSI de hasta 4 maquinas y obtuvimos buena eficiencia. Estamos conscientes que la infraestructura distribuida al igual que cualquier otra que utilice el trafico de red, presentara ciertas limitaciones al ejecutarse con una gran cantidad de maquinas por el exceso de trafico. Esto se podría mejorar recompilando el propio kernel de OpenSSI para soporte de una mayor cantidad de nodos. Con estas mejoras pensamos que podría mejorar el rendimiento.

4.2 MEJORAS A LOGRAR

- Optimizar el estándar TPC-C UVA para entornos distribuidos de alto rendimiento.

- Extender la herramienta de monitoreo WebView, con el modulo de administración para agregar y remover nodos por medio de su interfaz graficas.

- Implementar un sistema de almacenamiento que use múltiples discos, como alternativa al sistema de tolerancia de fallos SSIfailover del middleware.

- La mejora de los componentes físicos que participan durante el trafico de red, como ser placas de red mas veloces, un enrutador de mayor velocidad.

4.3 FUTURAS INVESTIGACIONES

De forma a continuar con el trabajo iniciado en esta tesis, los siguientes tópicos son propuestos para trabajos futuros:

- Evaluar las nuevas versiones de OpenSSI que ya aprovechan algunas arquitecturas de 64 bits;

- Realizar la implementación de la infraestructura SSI con instancias virtuales;
- Realizar pruebas con una gran cantidad de clientes;
- Evaluar la implementación de entornos elásticos sobre la infraestructura SSI.

BIBLIOGRAFÍA

[BEAS90] BEASLEY J. E. Linear programming on Cray supercomputers. The Journal of the Operational Research Society. Vol. 41, No. 2, Feb., 1990

[HILLI93] HILLIS W. Daniel and Tucker Lewis W. The CM-5 Connection Machine: A Scalable Supercomputer. Communications of the ACM, November 1993, Vol. 36, No. 11.

[BACK77] BACKUS John. Can programming be liberated from the von Neumann style? Communications of the ACM, 21(8), 1977

[INTE05] Excerpts from A Conversation with Gordon Moore: Moore's Law. G Moore - Interview by Intel Corporation. 2005

[BARN11] BARNEY Blaise. Introduction to Parallel Computing. 2011 [En Línea] https://computing.llnl.gov/tutorials/parallel_comp/

[COFF71] COFFMAN E. G., Elphick M, Shoshani A. System Deadlocks. Journal ACM Computing Surveys (CSUR) Volume 3 Issue 2, June 1971

[AMDA67] HL G. M, Validity of the Single-Processor Approach to Achieving Large Scale Computing Capabilities. In AFIPS Conference Proceedings, pages 483–485, April 1967

[HILL08] HILL Mark D. and Marty Michael R. Amdahl's Law in the Multicore Era. IEEE Computer 2008

[FLYN72] FLYNN. M. Computer organizations and their effectiveness. IEEE Trans-actions on Computers, September 1972

[DUNC90] DUNCAN Ralph. A Survey of Parallel Computer Architectures. IEEE

Computer Society Press. Vol 23, Issue 2, February 1990

[HWAN94] HWANG K., F. Briggs. Computer Architecture and Parallel Processing. McGraw-Hill. 1994

[FAN04] FAN Zhe, Qiu Feng, Kaufman Arie, and Yoakum-Stover Suzanne. GPU cluster for high performance computing. Proceedings of the 2004 ACM/IEEE Supercomputing Conference (SC'04), page 47059, November 2004

[BUYY99] BUYYA Rajkumar. High Performance Cluster Computing: Architectures and Systems, Volume 1. School of Computer Science and Software Engineering Monash University Melbourne, Australia. February 1999

[STER02] STERLING T. Beowolf Cluster Computing. The MIT Press. Cambrige, Massachusetts – London,England. 2002.

[TANE96] TANENBAUM, Andrew S. Sistemas operativos distribuidos. Prentice Hall Hispanoamericana. México. MX. 1996.

[SCHA02] SCHANTZ R. and Schmidt D. Research Advances in Middleware for Distributed Systems: State of the Art. In IFIP World Computer Congress, Kluwer Academic Publishers, pages 1-36, Canadá, August 2002.

[PFIS98] Greg PFISTER, In Search of Clusters, 2nd Edition, Prentice Hall 1998.

[SCHE98] Gang SCHEDULING. Timesharing on Parallel Computers, SC98, November 1998

[WALK99] WALKER, B., and Steel, D. Implementing a full single system image UnixWare cluster: Middleware vs. underware. Proceedings of the International Conference on Parallel and Distributed Processing Techniques and Applications. 1999.

[MATE95] MATENA Vlada, Thadani Moti N, Shirriff Ken, Khalidi Yousef A. and Bernabeu Jose M.. Solaris MC: A Multi-Computer OS. November 1995

[GHOR98] GHORMLEY, D., Petrou, D., Rodrigues, S.,Vahdat, A., and Anderson, T. GLUnix: A global layer Unix for a network of workstations. Journal of Software Practice and Experience. 1998 <http://now.cs.berkeley.edu/Glunix/glunix.html>

[BARA98] BARAK, A., and La'adan, O. The MOSIX multicomputer operating system for high performance cluster computing. Journal of Future Generation Computer Systems. 1998 <http://www.mosix.cs.huji.ac.il/>.

[LOTTI05] LOTTIAUX, R.; Gallard, P.; Vallee, G.; Morin, C.; Boissinot, B.; IRISA, Rennes. OpenMosix, OpenSSI and Kerrighed: a comparative study. France. May 2005

[MORI04] MORIN Christine, Lottiaux Renaud, Valle Geoffroy, Gallard Pascal, Margery David, Berthou Jean-Yves, and Scherson Isaac. Kerrighed and data parallelism: Cluster computing on single system image operating systems. In Proceedings of Cluster 2004. IEEE, September 2004

[DONG83] DONGARRA J. Performance of various computers using standard linear equations software in a Fortran environment. ACM SIGARCH Computer Architecture News. Volume 11 Issue 5, December 1983

[BAIL86] BAILEY D, Barton J. The NAS Benchmark Program. Numerical Aerodynamic Simulations Systems Division. 1986. http://www.tjhsst.edu/~rlatimer/mpi/nas-doc.pdf

[BOUT06] BOUTEILLER A, Herault T, Krawezik G, Lemarinier P, Cappello F. MPICH-V Project: A Multiprotocol Automatic Fault-Tolerant MPI. International Journal of High Performance Computing Applications 2006; 20; 319

[DONG95] DONGARRA L. Introduction to the HPC Challenge Benchmark Suite. 1995. http://icl.cs.utk.edu/hpcc/pubs/

[NUMR07] NUMRICH R. A note on scaling the Linpack benchmark. Journal of Parallel and Distributed Computing. v.67 n.4. 2007

[CHEN10] CHEN S. et all. TPC-E vs. TPC-C: Characterizing the New TPC-E Benchmark via an I/O Comparison Study. ACM SIGMOD V39, i3. 2010

[GARC08] GARCIA J. Proyecto Fin de Carrera: Una técnica para la caracterización de nodos en Redes de Sensores Inalámbricas. Escuela Técnica Superior de Ingeniería de Telecomunicación de la Universidad Politécnica de Cartagena. Julio de 2008

[LILJ05] LILJA D. Measuring Computer Performance: A Practitioner's Guide. Cambridge University. Pages: 133-134. 2005

[BERS92] BERSHAD B, et all. Using micro benchmark to evaluate System Performance. Schooll of computer science Carnegie Mellon university. IEEE Comput. Soc. Press, Pages: 148-153. 1992

[LIU04] LIU L. et all. Microbenchmark performance comparison of high-speed cluster interconnects. IEEE Computer Society. 2004.

[CHEN93] CHEN Peter M. and Patterson David A. Storage Performance - Metrics and Benchmarks. Computer Science Division, Dept. of EECS. University of California, Berkeley. 1993

[CURN76] CURNOW H J and Wichmann B A. A synthetic benchmark. Central Computer Agency, Riverwalk House, London SW1P 4RT. National Physical Laboratory, Teddington, Middlesex TW11 OLW. Computer Journal, Vol 19, No 1,

pp43-49. 1976

[SZEP11] SZEPKUTI I. Difference Sequence Compression of Multidimensional Databases. http://arxiv.org/abs/1103.3857 . 2011

[SPEC11] Standard Performance Evaluation Corporation. [En línea] http://www.spec.org. 28/09/2011

[TPCC11] Transaction Processing Performance Council .[En línea] http://www.tpc.org 2011

[BERR89] BERRY M. et all. The Perfect Club Benchmarks: Effective Performance Evaluation of Supercomputers. 1989

[OSDB10] The Open Source Database Benchmark. [En línea] http://osdb.sourceforge.net/ 22/12/2010

[NAPB10] NAS Parallel Benchmarks. [En línea] http://www.nas.nasa.gov/Resources/Software/npb.html 29/06/2010

[HPLB08] HPL - A Portable Implementation of the High-Performance Linpack Benchmark for Distributed-Memory Computers. [En línea] http://www.netlib.org/benchmark/hpl/. 28/09/2008

[WALK05] WALKER Bruce J, Hewlett-Packard. Open Single System Image Linux Cluster Project. [En linea] http://openssi.org/ssi-intro.pdf. Dec 2005

[SSID11] OPENSSI Documentation. [En línea] http://openssi.org/cgi-bin/view?page=docs. 04/10/2011

[IDGN11] INSTALLING DEBIAN GNU/Linux 5.0.9 [En línea]

http://www.debian.org/releases/lenny/debian-installer/ 03/11/2011

[GRUB11] GNU GRUB [En línea] http://www.gnu.org/software/grub/ 10/08/2011

[LILO10] LILO Bootloader for GNU/Linux. [En línea] http://lilo.alioth.debian.org/ 2010

[DONG97] DONGARRA J. J, Meuer H. W. and Strohmaier E, eds. TOP500 Report 1996, SUPERCOMPUTER , volumne 13, number 1, January 1997

[GRAY05] GRAY J. A "Measure of Transaction Processing" 20 Years Later. 2005.

[ZHOU99] ZHOU Y. et all. Fast Cluster Failover Using Virtual Memory-Mapped Communication. ICS Proceedings of the 13th international conference on Supercomputing 1999

[SHAN98] SHANLEY Kim. History and overview of TPC. [En línea] http://www.tpc.org/information/about/history.asp 1998

[TPCE10] TPC-Energy Specification V1.2.0. Transaction Performance Council. [En línea] http://www.tpc.org/tpc_energy/default.asp 2010

[LIMA09] LIMA, Murilo Rodrigues de; Sunye, Marcos Sfair Execução distribuída de benchmarks em sistemas de bancos de dados relacionados. Universidade Federal do Paraná. Setor de Ciencias Exatas. Programa de Pós-Graduaçao em Informática. 2009

[TUVA02] HERNANDEZ J., Hernandez E., Llanos D. TPC-C UVA Implementación del Benchmark TPC-C. Escuela Universitaria Politécnica de Valladolid, Universidad de Valladolid, España, 2002

[GNPL07] GNU General Public License. Free Software. [En línea] Fundationhttp://www.gnu.org/copyleft/gpl.html 29/06/2007.

[XIAO06] XIAO W., Liu Y., Yang Q. K., Ren J., and Xie C. Implementation and performance evaluation of two snapshot methods on iSCSI target stores. In Proceedings of IEEE/NASA Conf. Mass Storage Systems, 2006.

[HILL06] HILLAR Gastón C. PostgreSQL 8.1.4 Robusto y fácil de administrar. Mundo Linux: Sólo programadores Linux, ISSN 1577-6883, Nº. 91, págs. 52-56, 2006

[CARRA08] CARRASQUILLA U. Capacity planning for virtualization and consolidation. Junio 2008.

[POESS00] POESS M., Floyd C. New TPC Benchmarks for Decision Support and Web Commerce. ACM Sigmod Record, 2000

[BRAG03] BRAGADO, Ignacio Martín. Gnuplot. Gráficos y dibujos desde la línea de comandos. Sólo programadores Linux, pags. 18-24, 2003.

[DBGE00] DBGEN, An object Relational Relational Tool. [En línea] http://dbgen.sourceforge.net/ 03/07/2000

[MENE05] MENÉNDEZ A., Pérez J., Sebastiá J. Red de sensores inalámbricos para monitorización de terrenos mediante tecnología IEEE 802.15.4. [En línea] http://w3.iec.csic.es/ursi/articulos_modernos/articulos_gandia_2005/articulos/SC4/563.pdf 2005

[LINP08] THE LINPACK BENCHMARK. [En línea] http://people.sc.fsu.edu/~jburkardt/f_src/linpack_bench/linpack_bench.html 07/03/2008.

[LAPA11] LAPACK: Lineal Algebra Package. [En línea] http://www.netlib.org/lapack/ 19/04/2011

ANEXOS

INSTALACIÓN DEL SISTEMA OPERATIVO DEBIAN

La primera parte de la presente guía metodología para implementar una infraestructura clúster SSI consiste en instalar el nodo raiz. Para ello se utilizara la versión 5.0.8 de Debian, conocido como Lenny. Recomendada la version netinstall del mismo que se puede obtener desde la siguiente dirección.

```
1 http://www.debian.org/releases/lenny/debian-installer/
```

Netinstall significa que únicamente el sistema base se encuentra en la imagen .iso, los demás servicios se podrán descargar de internet posteriormente. Se recomienda que la partición este vacía, si es la primera vez que va a realizar una instalación Linux. Grabe el ISO en un CD e inicie desde el cdrom en la terminal que va a instalar.

Fig. 10 Pantalla de instalacion

INSTALACIÓN BASE DE DEBIAN

El proceso de la instalación se realiza en un modo consola. La terminal a instalar deberá de contar con dos placas de red, para mejor aislación entre la interconexión de nodos del cluster y la conexión a una red externa (internet). A continuación se detallan los pasos a pasos.

1. En la pantalla de Elegir Idioma, se selecciona “English”.

2. En la elección de País, se selecciona “United States”.

3. En la pantalla de seleccionar una configuración de teclado, se selecciona “American English”.

4. El hardware es detectado, los controladores y componentes se cargan, la red es ha configurada.

5. En la pantalla de configuración de red, se selecciona “eth0” como interfaz primaria de red.

6. En la pantalla de configuración de red, se selecciona como hostname “Lenny”

7. En la pantalla de configuración de red, se selecciona como nombre de dominio “clusterssi”.

8. Discos de almacenamientos son detectados y el proceso de partición es iniciado.

9. En la pantalla de partición de discos, se selecciona la opción “Manually edit partition table”

10. La partición se procederá de la siguiente manera. 1.0 Gb para la partición

/boot con sistema de archivos *ext3*, 0.5 Gb para la partición **/swap** y el espacio sobrante del disco se asigna a la partición **/** con sistema de archivos *ext3.*

11. El sistema base de Debian ha sido instalado

12. Se consultara acerca de instalar el cargador GRUB en el registro de inicio maestro, se responde “Yes”.

Configuraciones de Debian

Una vez instalado el sistema base de Debian, se procede a realizar configuraciones básicas del sistema operativos.

1. En la pantalla de configuración de Huso Horario, se selecciona “No” cuando se consulta si el reloj interno del hardware esta configurado a GMT.

2. En la pantalla de configuración de Huso Horario, se selecciona “other” y luego “South America”, “Paraguay” como huso horario.

3. Se ingresa y verifica una contraseña para el administrador “root”.

4. Se crea un usuario regular.

5. En la pantalla de configuración de paquetes APT, se selecciona “No” cuando se consulta si se desea examinar otro CD.

6. En la pantalla de configuración de paquetes APT, se selecciona “Yes” cuando se consulta acerca de agregar otro repositorio APT. Seleccione http, luego “United States” y luego “http://ftp.us.debian.org”. No es necesaria información para proxy HTTP.

7. Las configuraciones están hechas.

Una vez reiniciada la terminal la siguiente pantalla se visualizará el inicio de sesión de usuarios.

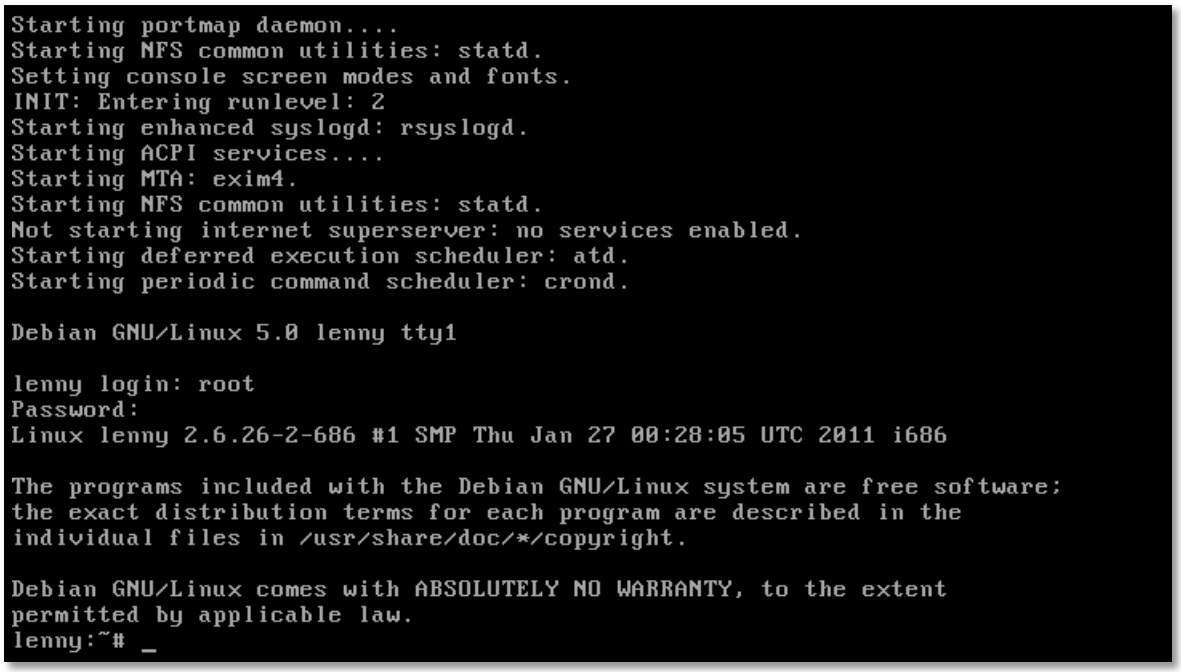

Fig. 11 Inicio de sesion

INSTALACIÓN DEL NODO INIT O MASTER

Posterior a la instalación del sistema operativo en la terminal que se desea usar como servidor o master (llamare master a partir de este momento) del cluster, se procede a las configuraciones para preparar al mismo. Se recomienda que se trabaje con únicamente la consola de Debian como entorno, ya que al instalar un entorno grafico, consumiría memoria ram, la cual puede ser utilizada de mejor manera en otros procesos del sistema.

Una vez iniciado el master con Debian Lenny instalado, se iniciara sesión como usuario administrador root, esto es para evitar escribir *sudo* a cada momento, luego de iniciada la sesión lo primero a realizar es la modificación del archivo "sources.list" de la siguiente manera.

```
1 nano /etc/apt/sources.list
```

Este se modificara para que quede de la siguiente forma:

```
1 deb http://ftp.us.debian.org/debian lenny main contrib
2 deb-src http://ftp.us.debian.org/debian lenny main contrib
3
4 deb http://security.debian.org/ lenny/updates main contrib
5 deb-src http://security.debian.org/ lenny/updates main contrib
6
7 deb http://deb.openssi.org/openssi 1.9.6-lenny-preview openssi extras
8 deb-src http://deb.openssi.org/openssi 1.9.6-lenny-preview openssi extras
```

Se crea el archivo "preferences" en la carpeta apt

```
1 nano /etc/apt/preferences
```

Con la finalidad de que al momento de realizar cualquier tipo de instalación de un paquete, el sistema tenga preferencia por aquellos que se encuentre en el servidor de OpenSSI, se agregan las siguientes líneas:

```
Package: *
Pin: origin deb.openssi.org
Pin-Priority: 1001
```

Por ultimo, con el fin de autorizar los paquetes no autenticados se crea el archivo 90auth para autenticación.

```
nano /etc/apt/apt.conf.d/90auth
```

Donde se ingresa la siguiente línea

```
APT::Get::AllowUnauthenticated "true";
```

Es importante que estos archivos contengan las líneas tal como se muestran expresadas para el correcta descarga e instalación de OpenSSI.

A continuación se ejecuta el comando *update* para actualizar repositorios y fuentes en Debian. Nota: si la salida de Internet es a través de un proxy se debe configurar primero, antes de continuar con los siguientes pasos.

```
apt-get update
```

Una vez realizada la operación anterior, se procede a instalar el paquete “initrd-tools”.

```
apt-get install initrd-tools
```

Se procede a desinstalar los siguientes paquetes:

```
apt-get remove nfs-common
apt-get remove libc6-amd64
```

Se procede a instalar el paquete “openbsd-inetd”

```
apt-get install openbsd-inetd
```

Se modificará el archivo de las interfaces de red:

```
nano /etc/network/interfaces
```

Se agrega al final del archivo lo siguiente

```
#Setting for the Cluster Interconnect
auto eth1
iface eth1 inet static
address 192.168.64.1
netmask 255.255.255.0
broadcast 192.168.64.255
```

Lo siguiente es agregar al modulo del NIC del grupo de interconexión al archivo modules, la tarjeta de red que el Master utilizara para comunicarse con los demás nodo, para obtener el NIC se usa la siguiente instrucción

```
ls -ld  /sys/class/net/ethX/device/driver/module
```

La “X” es el numero de identificación de la tarjeta de red (para saber que numero tiene la tarjeta de red que deseas usar solo coloca “ifconfig” en la consola). En este caso, seria eth1. El NIC es el código que se encuentra al final de la línea después del ultimo “/” este código se debe agregar en la ultima línea en el siguiente archivo.

```
cat /etc/mkinitrd/modules
```

Una vez agregado el código, se procede a remover el kernel actual del sistema, para ello se debe hacer *modprobe* a los módulos necesarios para construir el *initrd.*

ADVERTENCIA: a partir de este punto el sistema no será iniciable, por lo tanto

no se puede ni se debe apagar el master o cometer algún error, o sino será necesario comenzar de nuevo. Se realiza el modprobe de la siguiente forma:

```
1 modprobe loop
2 modprobe ext2
```

Ahora se debe instalar el kernel OpenSSI pre-compilado y se remueve el kernel actual, para ello se utiliza.

```
1 apt-get dist-upgrade
```

Nota I: si pregunta acerca abortar la remoción del kernel, se responde ”no”

Nota II: si durante la instalación pregunta acerca “portmap” se contesta “I” (i latina)(sin las comillas).

Una vez instalado el nuevo kernel se verifica que el “udev” este en la versión 0.080-1

```
1 dpkg -l udev
```

Si no se encuentra en esa versión, debe de ejecutarse:

```
1 apt-get install udev
```

Una vez concluida esta parte, se debe configurar el fichero /etc/udev/rules.d empezando asi:

```
1 ls /etc/udev/rules.d
```

Una lista similar a esta aparecerá

```
50-udev.rules               70-persistent-net.rules
60-persistent-input.rules       75-cd-aliases-generator.rules
60-persistent-storage.rules       75-persistent-net-generator.rules
60-persistent-storage-tape.rules  80-drivers.rules
60-persistent-v4l.rules           91-permissions.rules
70-persistent-cd.rules           95-late.rules
```

Para solucionar se deben de ejecutar las siguientes líneas:

```
rm /etc/udev/rules.d/*
bash -c 'source /var/lib/dpkg/info/udev.postinst abort-deconfigure; create_rules_symlink'
ls -l /etc/udev/rules.d
```

Obteniendo el siguiente resultado.

```
total 0
lrwxrwxrwx 1 root root 20 2009-04-11 12:25 020_permissions.rules -> ../permissions.rules
lrwxrwxrwx 1 root root 19 2009-04-11 12:25 cd-aliases.rules -> ../cd-aliases.rules
lrwxrwxrwx 1 root root 13 2009-04-11 12:25 udev.rules -> ../udev.rules
lrwxrwxrwx 1 root root 19 2009-04-11 12:25 z20_persistent.rules -> ../persistent.rules
lrwxrwxrwx 1 root root 12 2009-04-11 12:25 z50_run.rules -> ../run.rules
lrwxrwxrwx 1 root root 16 2009-04-11 12:25 z55_hotplug.rules -> ../hotplug.rules
lrwxrwxrwx 1 root root 17 2009-04-11 12:25 z70_hotplugd.rules -> ../hotplugd.rules
```

El paso a continuación es instalar openssi en el sistema con la siguiente instrucción.

```
apt-get install openssi
```

En caso de que al finalizar la instalación, no se soliciten configuraciones del master, ejecutar el comando *ssi-create*.

```
Unpacking linux-ssi-image-2.6-686-smp (from .../linux-ssi-image-2.6-686-smp_102.ssi3_i386.deb) ...
This command requires a CI/OpenSSI kernel.
Welcome to OpenSSI clustering!

Let's configure the first node in your cluster.

Enter a node number (1-125) or (?) [1]: 1

Select a network interface for the cluster interconnect.

    Name    IP address    Netmask        Hardware address
    ----    ----------    -------        ----------------
  1)    eth0    192.168.100.15    255.255.255.0    52:54:00:12:01:02
  2)    eth1    192.168.64.1    255.255.255.0    52:54:00:12:01:00

Select (1-3), (R)escan or (?) [1]: 2

Enter a clustername or (?): openssi-lenny

Do you want to enable root failover (y/n/?) [n]: y

The following configuration has been entered:
    Node number:        1
    NIC for interconnect:    eth1
    IP address:        192.168.64.1
    Network hardware addr:    52:54:00:12:01:00
    Local boot device:    UUID="967228e7-bdef-44cb-9f63-dd3d6dbd8e6c"
    Clustername:        openssi-lenny
    Root failover:        Yes
    Potential initnode:    Yes
    NFS support:        yes

(W)rite new configuration or (R)econfigure [W]: w
```

Estas son las configuraciones del OpenSSI para el master. Recuerde que la tarjeta de red previamente configurada para la interconexión es la que se debe utilizar. El siguiente paso es instalar un kernel que corregirá el problema de inicialización del sistema operativo.

Para instalar un kernel de 32 bits se ejecuta

```
1 apt-get install linux-image-2.6.14-ssi-686-smp
```

O para instalar un kernel de 64 bits se ejecuta

```
1 apt-get install linux-image-2.6.12-ssi-amd64
```

Lo siguiente a realizar es reiniciar el master usando el comando *init 6.* Una vez reiniciado el master con el kernel OpenSSI, el master se vuelve un cluster de un

nodo, por el momento, posteriormente se agregara mas nodos. El siguiente paso a realizar es modificar el archivo dhcpd.proto:

```
1 nano /etc/dhcp3/dhcpd.proto
```

Se agrega al final del archivo la siguiente línea:

```
1 next-server 192.168.64.1;
```

Luego se debe ejecutar el siguiente comando *mkdhcpd.conf*, se verifica que se haya generado el archivo dhcpd.conf

```
1 cat /etc/dhcp3/dhcpd.conf
```

Debería de mostrar algo similar a lo siguiente:

```
# /etc/dhcp3/dhcpd.conf
#
# Do _not_ edit this file!! It was automatically generated by mkdhcpd.conf.
#

# Section 1 (from /etc/dhcp3/dhcpd.proto)

next-server 192.168.64.1;

# Section 2 (from /etc/clustertab)

subnet 192.168.64.0 netmask 255.255.255.0 {
        host node1 {
            hardware ethernet 52:54:00:12:01:00;
            fixed-address 192.168.64.1;
        }

}
```

Se debe de reiniciar el proceso de dhcp3-server:

```
1 invoke-rc.d dhcp3-server restart
```

Ahora se debe asegurar de enlazar los directorios “/tftpboot” y “/var/lib/tftpboot” para ello se ejecuta:

```
1 ls -l /var/lib/tftpboot/
```

Lo cual debe de retornar en consola *total 0.* Luego se ejecuta:

```
1 mv /var/lib/tftpboot/ /var/lib/tftpboot.old
2 ln -s /tftpboot/ /var/lib/
3 ls /var/lib/tftpboot
```

Se obtiene:

```
combined  initrd  kernel  pxelinux.0  pxelinux.cfg
```

A partir de este momento se pueden agregar nodos a la infraestructura OpenSSI.

AGREGAR NODOS A LA INFRAESTRUCTURA.

Una vez instalado el sistema operativo en el nodo master, instalado el kernel openSSI en el mismo, se procede a agregar nodos para poder contar con una infraestructura Cluster. Para ello se deben realizar una serie de pasos y chequeos iniciando por la verificación si las tarjetas de red de los nodos esclavos no poseen soporte de booteo PXE. Se puede descargar un iso desde la siguiente url http://rom-o-matic.net/gpxe/gpxe-1.0.1/contrib/rom-o-matic/ Debido a que usaremos PXE, no es necesaria una imagen Etherboot.

Si el NIC de la tarjeta de red de los nodos esclavos no se encuentra en el archivo "/etc/mkinitrd/modules" del master. Se debe editar este archivo

```
nano /etc/mkinitrd/modules
```

Agregar el nombre del driver al final del archivo y luego reconstruir el ramdisk para contener los módulos necesarios para el inicio, debido a que este mismo ramdisk es el que se envía después a los nodos esclavos la imagen del SO. Para generar de nuevo el ramdisk se ejecutan los siguientes comandos:

```
mkinitrd -o /boot/initrd.img-2.6.14-ssi-686-smp 2.6.14-ssi-686-smp
ssk-ksync
```

Debido a que durante la instalación del sistema operativo al nodo master, se ingresó la opción noapic, es necesario realizar una modificación dentro del archivo /tftpboot/pxelinux.cfg/default.

```
nano /tftpboot/pxelinux.cfg/default
```

Se agrega "noapic" antes del initrd de la siguiente manera:

```
append noapic initrd=images/pmagic/initrd.gz root=/dev/ram0 init=/linuxrc ramdisk_size=100000
```

Una vez hechas estas configuraciones en el nodo master. Se procede a iniciar el nodo esclavo con la imagen ISO gPXE. En el nodo esclavo, se podrá apreciar como la imagen gPXE se inicia y busca algún servidor DHCP, presionando de manera combinada las teclas CTRL + B se accede a la consola, al ingresar el comando *autoboot* se obtendrá la dirección MAC de la tarjeta de red que se utilizará para la interconexión con el cluster.

En el nodo master se ejecuta el comando *ssi-addnode* de la siguiente manera:

```
ssi-addnode --hwaddress="MACADDRESS"
```

En donde MACADDRESS es la dirección MAC del nodo esclavo que se encuentra ejecutando gPXE. Al ejecutar el comando *ssi-addnode* se realizaran algunas preguntas acerca de cómo se desea configurar el nuevo nodo y que son los siguientes.

```
Do you want verbose prompts (y/n) [y]:
```

Se ingresa “Y”

```
Enter a node number (2-125) or (?) [2]: 2
```

Se ingresa “2”

```
Select (P)XE or (E)therboot as the network boot protocol for
this node. PXE is an Intel standard for network booting, and
many professional grade NICs have a PXE implementation pre-
installed on them. You can probably enable PXE with your BIOS
configuration tool. If you do not have a NIC with PXE, you can
make use of open-source project Etherboot, which lets you generate
a floppy or ROM image for a variety of different NICs.

Select (P)XE, (E)therboot or (?) [E]: P
```

Se ingresa “P”

```
The nodename should be unique in the cluster and it should
resolve to one of this node's IP addresses, so that client
NFS can work correctly. The nodename can resolve to either
the IP address you configured above for the interconnect,
or to one of external IP addresses that you might configure
below. The nodename can resolve to the IP address either in
DNS or in the cluster's /etc/hosts file.

The nodename is stored in /etc/nodename, which is a context-
dependent symlink (CDSL). In this case, the context is node
number, which means each node you add will have it's own view
of /etc/nodename containing its own hostname. To learn more
about CDSLs, please see /usr/share/doc/openssi/cdsl.

Enter a nodename or (?): lenny-node2
```

Se ingresa “Lenny-node2” o el nombre que se escoja para el nodo.

```
Do you want this node to be a root failover node? It _must_
have access to the root filesystem on a shared disk in order
to answer yes. If you answer yes, then this node can boot
first as a root node, so you should configure it with a local
boot device. This is done after this node joins the cluster
and is described in the installation instructions.

Enable root filesystem failover to this node (y/n/?) [n]: y
```

Si en el master se activo la tolerancia a fallos, se ingresa aquí “Y”. Una vez guardadas estas configuraciones, el nodo esclavo se unira al cluster por red.

Para comprobar el estado del cluster ejecutar el siguiente comando

```
lenny:~# cluster -v
1:  UP
2:  UP
```

Para la tolerancia de falla en el cluster, se deben realizar los siguientes pasos.

```
lenny:~# onnode 2 /bin/sh
lenny-node2:~# mkfs -t ext3 /dev/sda1
mke2fs 1.40-WIP (14-Nov-2006)
Filesystem label=
OS type: Linux
Block size=1024 (log=0)
Fragment size=1024 (log=0)
126976 inodes, 506016 blocks
25300 blocks (5.00%) reserved for the super user
First data block=1
Maximum filesystem blocks=67633152
62 block groups
8192 blocks per group, 8192 fragments per group
2048 inodes per group
Superblock backups stored on blocks:
    8193, 24577, 40961, 57345, 73729, 204801, 221185, 401409

Writing inode tables: done
Creating journal (8192 blocks): done
Writing superblocks and filesystem accounting information: done

This filesystem will be automatically checked every 28 mounts or
180 days, whichever comes first.  Use tune2fs -c or -i to override.
```

Luego se ejecuta el comando *ssi-chnode*

```
lenny-node2:~# ssi-chnode
Select a node number (1,2) [1]: 2

Select (P)XE, (E)therboot or (?) [P]: P
Enter a new boot device: /dev/hda1

The following configuration has been entered:
    Node number:        2
    IP address:        192.168.64.2
    Network hardware addr:    52:54:00:12:02:00
    Network boot protocol:    PXE
    Local boot device:    UUID="ea073072-54be-4b60-9fcf-88a871c69fdc"
    Potential initnode:    Yes

(W)rite new configuration, (R)econfigure, or (Q)uit without writing [W]:
The configuration changes have been saved.
Do you wish to configure another node (y/n) [n]:
Rebuilding the boot materials
/tmp/initrd.OzHutZ:     69.3%
Synchronizing network boot images: succeeded
Stopping DHCP server: dhcpd3.
Starting DHCP server: dhcpd3.
Synchronizing local boot devices
    syncing UUID="967228e7-bdef-44cb-9f63-dd3d6dbd8e6c" on node 1:    succeeded
    syncing UUID="ea073072-54be-4b60-9fcf-88a871c69fdc" on node 2:    succeeded

Node 2 has been updated.
```

A partir de este momento, el nodo puede iniciar desde su propio disco. Repita los pasos para agregar mas nodos al cluster OpenSSI.

INSTALACIÓN DE LA HERRAMIENTA VISUAL DE MONITOREO.

BENCH TPCC-UVA

BENCH TPCH

SCRIPT PARA INSTANCIAR EL POSTGRES PARA PRUEBAS OLTP

SCRIPTS UTILITARIOS PARA PRUEBAS OLAP

DESCRIPCIÓN TÉCNICA DE EQUIPOS

ANEXO DE FORMULARIO DE PRUEBAS